Universidad Autónoma de Yucatán

Facultad de Matemáticas - UADY

Licenciatura en Ingeniería de Software

Identificación automática de las lenguas habladas: maya, zapoteco, y nahuátl, mediante modelos de aprendizaje profundo

Propuesta de Tesis

presenta:

Breindel Várguez González

Directores:

Dr. Jorge Carlos Reyes Magaña
Dra. Silvia Fidelina Fernández Sabido

Mérida, Yucatán, 2026

Índice general

1. Introducción **2**

2. Objetivos **5**

3. Marco teórico **6**

4. Metodología **16**

5. Conclusiones **20**

Bibliografía **23**

Capítulo 1

Introducción

Si bien el 13 de marzo de 2003 se declararon a las 68 lenguas indígenas principales de México como lenguas oficiales a la par que el español [20], lo cierto es que actualmente las personas de las comunidades indígenas que no hablan español viven en una condición de vulnerabilidad debido a la barrera del lenguaje en las instituciones públicas. Para ayudar a estas personas, organizaciones como el Instituto Nacional de Lenguas Indígenas (INALI[1]) por medio del Padrón Nacional de Intérpretes de Lenguas Indígenas (PANITLI[2]) brindan el apoyo en localizar intérpretes de lenguas indígenas, sin embargo el primer paso para la prestación de este servicio es identificar qué lengua indígena está hablando esta persona, pero la mayoría de la población que solamente habla español puede encontrar dificultad en distinguir entre idiomas indígenas, derivando esto en que el servicio de traducción brindado sea inutilizable.

Para entender el contexto actual de las comunidades indígenas es útil recordar su origen. México se encuentra geográficamente en la zona donde surgieron las áreas culturales de Mesoamérica, Oasisoamérica y Aridoamérica [32]. Los primeros seres humanos en llegar a la región entraron por movimientos migratorios de hace aproximadamente 16,000 años, el sitio con ocupación humana más antigua en la región se remonta al 12,000 a.C. y la civilización Olmeca es la primera de la cual se tiene registro apareciendo aproximadamente en el año 1200 a.C [27].

Conforme avanzaba el tiempo las civilizaciones mesoamericanas fueron extendiéndose y diversificándose por toda la región llegando a crear ciudades como Monte Albán, Teotihuacán y Tenochtitlán las cuales llegaban a varias decenas de miles de habitantes [27]. Los pueblos más grandes como los mexicas y mayas contaron con idiomas e inclusive escritura propia, las cuales evolucionaban a la par que se transformaban las sociedades de la región [21].

Después de la conquista española y la muerte de la gran mayoría de la población de Mesoamérica por infecciones y enfermedades, resultado del contacto de poblaciones tan separadas, así como otras causas relacionadas con guerras y esclavitud, la población indígena se redujo y comenzó a ser oprimida y dispersada mientras los españoles impusieron su cultura y por ende su idioma en toda la región [9, 25]. Desde el siglo XVI hasta los tiempos actuales las necesidades de las comunidades indígenas han sido relegadas por

[1] https://www.inali.gob.mx

[2] https://siip.inali.gob.mx

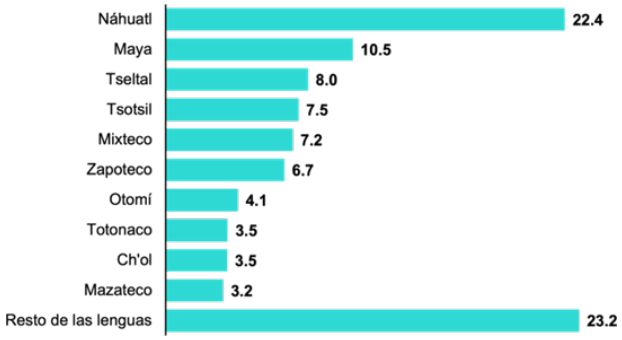


Figura 1.1: Distribución hablantes de lengua indígena por lengua (porcentaje). Tomado de: [17]. Fuente: INEGI. Censo de Población y Vivienda 2020. Cuestionario Básico. Consulta interactiva de datos.

gobernantes, políticos y personas en el poder, es por eso que su situación actual cuenta con altas tasas de pobreza, marginación social y bajos índices de calidad de vida [1, 28].

Actualmente, gracias a la tarea de investigación antropológica y lingüística conocemos que como resultado de todo este contexto histórico en todas las comunidades indígenas en México existen 11 familias lingüísticas, de las cuales surgen las 68 lenguas reconocidas oficialmente con un total de 364 variaciones registradas [19].

La cantidad de hablantes de lenguas indígenas en el país es de más de 7 millones de personas representando un 6.1 % de la población total para 2020. Como se puede apreciar en la Figura 1.1 la distribución poblacional por lengua es desigual ya que 5 de las 68 lenguas oficiales comprenden más de la mitad de esta población [17].

Si bien no son pocas las personas que hablan lenguas indígenas, la marginación de estas comunidades y la inmensa variabilidad de las lenguas se ha traducido en que en estos últimos años después de la revolución tecnológica digital no se han podido hacer registros escritos, auditivos o visuales. A diferencia de las personas hispanohablantes u otras lenguas mayoritarias cuyos recursos se han almacenado en grandes cantidades a través de videos subidos a internet, producción de música, películas, etc. [11].

Esta situación impacta en los procesos de desarrollo de tecnologías en lenguas indígenas, ya que el desarrollo de tecnologías de reconocimiento de idiomas por voz en tiempos actuales debe su precisión a los grandes registros que se han hecho de los idiomas más hablados en el mundo, mientras que la realización de tecnologías de reconocimiento en estas lenguas indígenas sería inviable siguiendo los mismos métodos empleados tradicionalmente con los idiomas más hablados debido al poco material de estudio digital con el que se cuenta hoy en día [3].

Es debido a problemáticas similares en distintas partes del mundo que se han desarrollado nuevos métodos y tecnologías de reconocimiento de idiomas con los que se puede mantener una precisión alta aún con un número bajo de muestras para su estudio. Por ejemplo un equipo de la India en el 2020 [23] y un equipo en Indonesia en 2021 [33] desarrollaron y entrenaron modelos de inteligencia artificial capaces de reconocer el idioma que habla una persona. En el caso del equipo Indio logró una puntuación de 99 % de exactitud de entre los más de 100 idiomas hablados en la región, mientras que el equipo de Indonesia logró una puntuación del 90 % de exactitud identificando los 4 idiomas locales

principales, ambos trabajos tienen la misma característica de contar con una muestra de estudio reducida.

Este tipo de avances sientan una base técnica que abre las puertas a desarrollos similares en México, orientados a generar un impacto positivo y dignificar las lenguas indígenas. Esto toma importancia ya que, según datos del programa IMSS-Bienestar, para 2025 se registraron 3.8 millones de personas adscritas en localidades indígenas, con una infraestructura de 81 hospitales y 3,621 Unidades Médicas operando en localidades rurales bajo dicho programa [16]. La barrera lingüística es una de las tantas dificultades que tienen estas comunidades para acceder a servicios públicos como salud [7, 29] y justicia [22], por lo que crear un sistema capaz de reconocer el idioma hablado es un paso para mejorar el acceso de las personas indígenas a sus derechos humanos.

El desarrollo de este proyecto se centrará en el reconocimiento entre el Maya, Náhuatl, y Zapoteco ya que son los idiomas con suficiente disponibilidad de información y contenido digital actualmente. Esta investigación también busca que el proyecto sea capaz de integrar fácilmente más idiomas conforme la disponibilidad, calidad y cantidad de audios sea mayor. Realizar este sistema y evaluar su desempeño puede ser de utilidad para los trabajos relacionados a las tecnologías de la información con familias, lenguas y variantes lingüísticas indígenas y en un futuro brindar una mejor atención a las comunidades originarias en diferentes instituciones públicas, de salud y justicia.

Capítulo 2

Objetivos

El objetivo principal de este proyecto es desarrollar un modelo de inteligencia artificial para la clasificación de las lenguas indígenas Maya, Náhuatl y Zapoteco en formato de audio, considerando el modelo más eficiente para su identificación.

- Identificar las diferentes metodologías existentes que tengan los mejores resultados en tareas de clasificación de audio, específicamente para la clasificación del idioma hablado.
- Recepción del corpus de audio, ejecutando las tareas de descargar y clasificar el material que será usado para el entrenamiento. Considerando un balance de cantidad, duración y calidad de los audios audios para asegurar que los sesgos en el entrenamiento sean los mínimos posibles.
- Preprocesar el corpus con el formato y las especificaciones requeridas para su adecuado manejo por las tecnologías de aprendizaje que se utilizarán.
- Implementar las metodologías identificadas para la clasificación de audio con el corpus recopilado y preprocesado, registrando los resultados de una forma adecuada para su análisis comparativo.
- Análisis del mejor modelo de clasificación con base en la experimentación, asegurando un desempeño adecuado en los entornos reales donde se aplicaría este modelo.
- Integración del modelo seleccionado en una aplicación móvil con el sistema operativo Android, para su posible despliegue en un entorno realista.

Capítulo 3

Marco teórico

Características del Náhuatl, Maya y Zapoteco

Los modelos de aprendizaje profundo para la clasificación de la lengua hablada abarcan una serie de técnicas: *feed-forward deep neural network, convolutional neural network, long short term memory-recurrent neural network, etc.* Cada una de ellas toma en cuenta diferentes características, entre las cuales se encuentran: la fonética acústica (frecuencia y amplitud), fonotáctica (restricciones en las combinaciones de sonido), prosodia (acento, tono y ritmo), vocabulario y sintáxis (estructura y reglas de combinación de palabras) para el reconocimiento de patrones de forma end to end [10]. Todas estas características pueden ser similares entre distintas lenguas indígenas y en mayor medida si comparten la misma familia lingüística. Para el objetivo de este proyecto solamente se trabajarán con 3 lenguas indígenas las cuales provienen de diferentes familias:

- Nahuatl: una lengua en alto grado aglutinante (formando palabras complejas a partir de morfemas), lo cual confiere grandes posibilidades de expresión, además de notables diferencias fonéticas [31], viene de la familia Yuto-nahua, y cuenta con 30 variantes habladas en diferentes estados del centro del país, principalmente en estados como Veracruz, Puebla, Guerrero e Hidalgo [19].

- Maaya t'aan: una lengua de la familia lingüística Maya, hablada en la península de Yucatán y con las características de ser aglutinante, sin artículos ni género en cada palabra, con abundancia de sonidos consonánticos sordos, como la pronunciación de k' sin el uso de una vocal, y consonantes glotalizadas, así como vocales largas con diferentes tonalidades [12].

- Zapoteco: se caracteriza por ser una lengua tonal, por lo que según la variación de altura y tono en las sílabas cambian los significados de las palabras; dependiendo de la variante puede haber de 3 a 5 tonos y de 4 a 7 vocales con pronunciaciones cortadas quebradas o modales [4]. Proviene de la familia Oto-Mangue y es la lengua con más variantes de entre estas 3 con un total de 63 variantes registradas habladas principalmente en el Estado de Oaxaca [19].

Las lenguas indígenas en las tecnologías de la información

El desarrollo de recursos digitales para las lenguas indígenas de México ha avanzado de manera gradual gracias a esfuerzos tanto institucionales y académicos, pero sobre todo por parte del activismo de los mismos hablantes nativos. Entre los trabajos de carácter tecnológico destacan las recopilaciones digitales de audio del INALI en formato de prontuarios los cuales concentran frases esenciales en los 68 idiomas indígenas oficiales [18]. Así mismo se han difundido corpus digitales, como "Entendámonos" [1] para el náhuatl, tének y xi'iuy; y el sitio web "Uuytaan"[2] para el maya, los cuales representan un avance importante en la disponibilidad de material lingüístico estructurado.

Complementando estos esfuerzos, distintas iniciativas en línea han contribuido a la difusión y preservación de estas lenguas. Hablando sobre las 3 lenguas mencionadas anteriormente, sitios web como Nahuatl.mx ofrecen recursos de aprendizaje con materiales de audio; Zapoteco del Istmo[3] pone a disposición del público materiales de gramática y vocabulario del zapoteco del istmo; y U Péekbal Waye'[4] que funge como medio entre activistas de la lengua maya para la difusión y organización de sus actividades comunitarias. En conjunto, estas plataformas y demás materiales como los distribuidos por el sitio web del INALI favorecen la difusión, integración y conservación de las lenguas indígenas.

Sin embargo, persisten limitaciones en cuanto a la cantidad y variedad del material disponible, especialmente en comparación con los recursos existentes para idiomas mayoritarios. Esta escasez de contenido digital es el contexto en el que se muestran los trabajos revisados a continuación sobre modelos de aprendizaje profundo para el reconocimiento de lengua hablada.

Tecnologías para la clasificación de audio

La identificación automática de lengua hablada ha evolucionado significativamente en los últimos años gracias al uso de modelos de aprendizaje profundo. De manera general, los enfoques actuales para esta tarea pueden agruparse en dos categorías principales. Por un lado, se encuentran los modelos que procesan directamente la señal de audio, extrayendo sus características más relevantes y utilizándolas como entrada para clasificadores basados en aprendizaje profundo. Por otro lado, existen enfoques que transforman el audio en representaciones visuales, como espectrogramas, lo que permite abordar el problema como una tarea de clasificación de imágenes. Este segundo enfoque se apoya en el amplio desarrollo de las técnicas de reconocimiento de imágenes por computadora, donde diversas arquitecturas han demostrado una alta capacidad para identificar patrones en representaciones gráficas del audio, particularmente en espectrogramas.

A continuación se describen algunas de las arquitecturas más relevantes para este tipo de tareas.

[1] https://rinacional.tecnm.mx/bitstream/TecNM/3069/1/G06070532_donacion_tesis_bib.pdf
[2] https://uuytaan.lenguasindigenas.org/landing
[3] https://zapotecojuchitan.org/
[4] https://www.waye.red

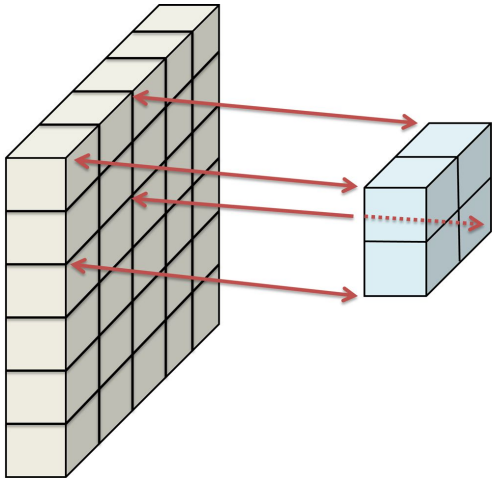


Figura 3.1: Representación de abstracción con convolución

.

Convolutional Neural Networks (CNN)

Las redes neuronales convolucionales, son la metodología de clasificación de imágenes más utilizada debido a su alta capacidad para detectar patrones en los datos. En el contexto de la identificación de lengua hablada, estas redes se aplican sobre representaciones visuales del audio, en nuestro caso con los espectrogramas *log-mel*. Esta arquitectura para la clasificación de lengua hablada maya y español fue utilizada para la realización de un modelo en 2025[5] [6], obteniendo resultados preliminares positivos. Adicionalmente, en [8] se presenta la implementación de un modelo ligero para la clasificación maya-español.

Las CNN se basan en el concepto de convolución, el cual consiste en aplicar filtros que recorren la imagen de entrada para extraer características locales como bordes, formas y patrones. A medida que se profundiza en la red, las capas convolucionales permiten identificar características cada vez más abstractas y complejas como se peude representar en la Figura 3.1.

La arquitectura típica incluye capas de convolución, funciones de activación no lineales, capas de agrupamiento para reducir la dimensionalidad, y finalmente capas completamente conectadas para la clasificación.

Wav2Vec

Wav2Vec es un marco de aprendizaje auto-supervisado enfocado en reconocimiento de voz a partir de audio crudo. El modelo [5] consta de 3 partes secuenciales, primeramente se extraen las características principales mediante un encoder convolucional, después utiliza estas características extraídas para alimentar una red de contexto con una arquitectura de transformador y finalmente utiliza un módulo de cuantización el cual refleja la continuidad del audio.

El entrenamiento en esta arquitectura se caracteriza por utilizar la técnica de enmascaramiento, la cual oculta partes del audio y realiza una predicción para las partes ocultas,

[5]https://github.com/JeanBuenfil/Language-Classification-CNN

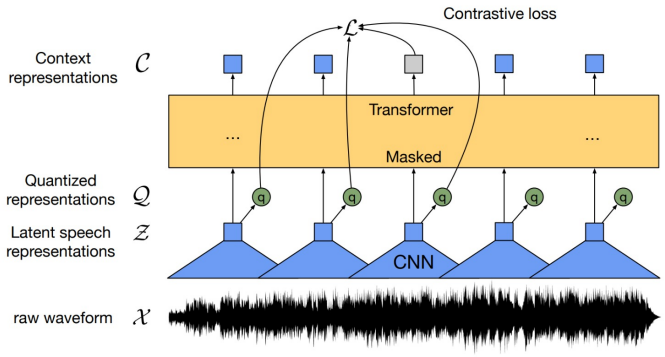


Figura 3.2: Marco de trabajo de *Wav2Vec*

.

lo cual mejora la capacidad de entender los audios como contexto en lugar de solamente quedarse con las características estáticas de estos audios. Toda esta arquitectura se puede ver representada en la Figura 3.2 y es accesible mediante pytorch con la capacidad de ajustar ciertos parámetros internos.

Una vez procesado el audio en el formato de vector, se añade una capa de clasificación que permite asignar una probabilidad a cada una de las lenguas objetivo. Durante el entrenamiento, se ajustan los pesos del modelo utilizando técnicas de *fine-tuning* sobre el modelo preentrenado, lo cual permite aprovechar el conocimiento previamente adquirido y adaptarlo a alguna tarea específica.

Time Delay Neural Network (TDNN) *x-vector*

La característica principal de las TDNN es su capacidad para modelar dependencias temporales en señales secuenciales, como el audio, mediante el análisis de múltiples ventanas de tiempo dentro de la señal de entrada. Esto permite capturar patrones temporales relevantes sin necesidad de recurrir a mecanismos recurrentes, lo que las hace computacionalmente eficientes para tareas de procesamiento de voz.

El concepto de x-vector se basa en la extracción de representaciones vectoriales de longitud fija a partir de señales de audio de duración variable. Estos vectores, conocidos como *embeddings*, condensan la información más importante del habla en una representación compacta.

En el estudio de Prabhu et al. [26], se combinan ambos conceptos mediante una arquitectura basada en TDNN para la generación de *x-vectors* orientados a la tarea de identificación de lenguas. En este enfoque, las características del audio son procesadas por una serie de capas TDNN que capturan patrones temporales en la señal. Posteriormente, se incorpora una capa de *statistical pooling*, la cual permite transformar las representaciones dependientes del tiempo en un vector de dimensión fija, independientemente de la duración del audio. Este vector es procesado por dos capas densas adicionales antes de ser alimentado a la capa de salida para su clasificación.

Este tipo de arquitectura permite no solo realizar clasificación de manera end-to-end, sino también utilizar los *x-vectors* como representaciones intermedias que pueden ser

aprovechadas por clasificadores tradicionales de aprendizaje automático, como *K-Nearest Neighbors* (KNN) o *Support Vector Machines* (SVM), lo que facilita la combinación de métodos de aprendizaje profundo y aprendizaje clásico.

Long Short Term Memory (LSTM)

LSTM es un tipo de red neuronal recurrente diseñada para modelar dependencias temporales en secuencias de datos, como señales de audio. A diferencia de las redes recurrentes tradicionales, las LSTM incorporan mecanismos internos llamados compuertas, específicamente: compuerta de entrada, compuerta de olvido y compuerta de salida. Estas compuertas permiten controlar el flujo de información a lo largo del tiempo, decidiendo qué información conservar, actualizar o descartar.

Gracias a este mecanismo, las LSTM son capaces de aprender relaciones a largo plazo en los datos, lo cual es especialmente útil en el reconocimiento de patrones en el habla, donde el contexto temporal influye significativamente en la interpretación de los sonidos [24].

Arquitecturas híbridas

Las arquitecturas híbridas en la identificación de lengua hablada combinan distintos enfoques de aprendizaje profundo, integrando múltiples representaciones del audio con el objetivo de mejorar el desempeño del sistema.

Un enfoque común dentro de estas arquitecturas consiste en utilizar modelos preentrenados como extractores de características. Estos modelos generan representaciones del audio que capturan distintos aspectos del habla debido a las diferencias en sus arquitecturas y procesos de entrenamiento.

Una estrategia relevante dentro de este enfoque es el *Multi-View Learning*, en el cual múltiples representaciones de un mismo audio son procesadas de manera independiente y posteriormente fusionadas. Esta fusión permite capturar información complementaria presente en cada representación, generando un *embedding* más completo y representativo.

Una vez obtenidos estos *embedding*, se pueden emplear distintas estrategias de clasificación. Por un lado, es posible realizar una clasificación end-to-end mediante capas densas finales; por otro lado, los *embedding* pueden utilizarse como entrada para clasificadores tradicionales de aprendizaje automático, permitiendo combinar la capacidad de representación del aprendizaje profundo con la simplicidad de estos métodos. En la Figura 3.3 se muestra un ejemplo de este tipo de enfoque, donde se integran distintos extractores de características y modelos de *embedding* para realizar la clasificación final.

Trabajo relacionado

El aprendizaje profundo es un subconjunto del aprendizaje máquina impulsado por redes neuronales multicapa cuyo diseño está inspirado en la estructura del cerebro humano [15]. Los modelos de aprendizaje máquina empaquetan el modelo obtenido por el entrenamiento, lo que permite utilizarlos posteriormente para realizar inferencias. Para los objetivos de esta tesis se ahondará en dos áreas principales de estudio e investigación: el

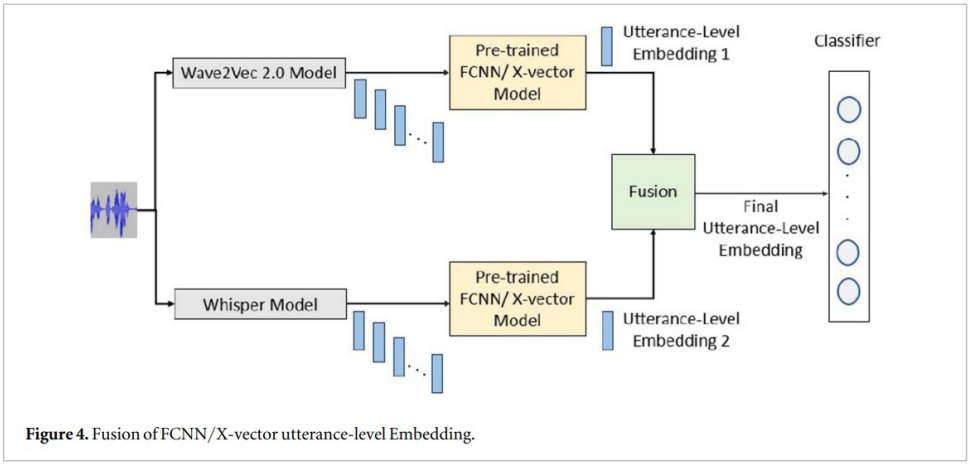


Figura 3.3: Ejemplo de una arquitectura híbrida

.

reconocimiento de la lengua hablada y la portabilidad de modelos en tecnología móvil. En ambos casos, los métodos presentados a continuación se basan en aprendizaje profundo.

Tarea de reconocimiento de lengua hablada

Con el fin de cumplir el objetivo principal de esta investigación se revisaron trabajos orientados a la clasificación automática de idiomas a partir de audio. Los trabajos identificados emplean distintos enfoques y métodos para abordar esta tarea:

Identificación de lengua hablada para detectar lenguajes de la costa Karnataka usando *transfer learning* y *multi-view learning*

El trabajo de Prabhu *et al* [26], desarrollado en India, tuvo como objetivo construir un modelo de clasificación para las lenguas Kannada, Konkani y Tulu, las cuales cuentan con escasos registros digitales, lo que dificultaba la realización de estudios similares.

Para compensar la falta de datos, se aumentó el conjunto de muestras introduciendo ruido y perturbaciones de velocidad, simulando así condiciones más realistas de captura de audio. Se emplearon dos modelos para la extracción de características relevantes: *Wav2Vec* y *Whisper* base; y se evaluaron tres arquitecturas: *Fully Connected Neural Network* (FCNN), *X-vector* basado en TDNN y *Multi-View Learning*, que combina las características extraídas por ambos modelos.

Como resultado se concluyó que el aumento artificial de la muestra con ruido y cambios en las velocidades mejoró las puntuaciones de precisión. La arquitectura con el mejor resultado fue *Multi-View Learning* con una precisión de 96 % y adicionalmente se destaca que los audios de poca duración como los de 3 segundos tenían caídas de precisión del 5-8 %.

Identificación de lengua hablada en 4 lenguas locales de Indonesia

Wijonarko *et al* [33] desarrolló un trabajo similar realizado en Indonesia con el objetivo de clasificar entre las lenguas Javanés, Sundanés, Minangkbau y Buguinés que igualmente cuentan con pocos datos digitales, pero a diferencia del trabajo anterior, en este se limpiaron los audios de la muestra, eliminando la música y ruido de fondo con el objetivo de inferir con audios más claros.

El enfoque de este estudio se centró en el uso de espectrogramas de tipo *Mel Frequency Cepstral Coefficient* (MFCC) y en la clasificación de imágenes generadas a partir de dichos espectrogramas, en lugar de procesar el audio directamente. Se estudió el desempeño de las arquitecturas Artificial Neural Network (AAN), CNN y LSTM con audios de 3, 10 y 30 segundos. Todas superaron el 85 % de precisión en las tres duraciones, sin embargo, LSTM destacó con un 88.8 % en audios de 10 segundos.

Aprendizaje profundo para identificación de lengua hablada: ¿Podemos visualizar los patrones de señales del voz?

Mukherjee *et al* [23] abordó la identificación de siete lenguas locales en la India mediante espectrogramas MFCC procesados con una arquitectura CNN. La particularidad de este trabajo fue alcanzar una precisión del 99.96 %, superando el estado del arte previo para esos idiomas. Además, el modelo mantuvo un rendimiento robusto en condiciones de ruido, con una precisión del 99.46 %, lo que demuestra la eficacia de este enfoque para reconocer patrones de voz incluso en condiciones desfavorables.

Procesamiento inteligente de señales de voz

Das *et al* [10] hacen un análisis del uso de diferentes arquitecturas de procesamiento de imágenes en la tarea de identificación de lengua hablada como lo son *Feed-Forward Deep Neural Network* (FF_DNN), CNN y LSTM-*Recurrent Neural Network* (RNN). En este análisis se describe que los patrones de audio que identifican los modelos de aprendizaje profundo están relacionados a los sonidos, sus frecuencias, reglas de combinación así como al ritmo, tono y acentuación de las palabras e inclusive la estructura de las oraciones. Como resultado del análisis presentado se observó que los modelos híbridos, aquellos que combinaban 2 arquitecturas, superaron sistemáticamente a los modelos individuales, y que el uso de segmentos con duración de entre 3 y 10 segundos son los más adecuados debido a la aplicabilidad en entornos de uso real.

Identificación del lenguaje hablado mediante aprendizaje profundo

Sing *et al* [30] recopiló las principales arquitecturas en el área de reconocimiento de la lengua hablada usando espectrogramas MFCC y *Log-Mel*, evaluándolas sobre los mismos datos de prueba. Los resultados concluyeron en que la arquitectura CNN fue la más precisa con diferencia con una puntuación de 99 para las métricas F1, Precisión y Exhaustividad (*Recall*). Otras tecnologías que obtuvieron puntuaciones considerables fueron ResNet50 con puntuaciones arriba de 82 y CapsNet con puntuaciones arriba de 89 ambas para los 3 tipos de métricas.

Estudio comparativo sobre la identificación del lenguaje hablado mediante aprendizaje profundo

En este trabajo comparativo Heracleous *et al* [14] estudiaron las arquitecturas SVM, *Deep Neural Networks* (DNN) y CNN. El objetivo fue comparar el desempeño de estos tres métodos de clasificación usando representaciones compactas de audio llamadas i-vectors, sobre un conjunto de 50 idiomas. Siguiendo esta metodología se observaron resultados favorables para las arquitecturas DNN y CNN con un *Equal Error Rate* (ERR) de 3.55 % y 3.48 % respectivemente, sin embargo en este estudio también se comprobó que los modelos híbridos tuvieron mejores resultados que los modelos individuales, obteniendo el mejor resultado la fusión de CNN y SVM con un ERR de 2.79 %. Este tipo de estudios que manejan una cantidad considerable de lenguajes abren la puerta para trabajos similares ya que representan la posibilidad de clasificar el idioma hablado de entre decenas de idiomas con resultados positivos.

A partir de la revisión de estos trabajos se puede concluir que el estado del arte actual en la tarea de identificación de lengua hablada gira principalmente en torno al análisis de espectrogramas de voz mediante aprendizaje profundo. En particular, los trabajos con mejores resultados emplean redes neuronales convolucionales fusionadas con otras arquitecturas de aprendizaje, las cuales han demostrado ser eficaces para identificar patrones acústicos y fonéticos en las representaciones visuales del audio. Este enfoque será el punto de partida metodológico para la presente investigación.

Uso de modelos de aprendizaje profundo portables en tecnología móvil

Una tendencia creciente en el campo del aprendizaje profundo es la optimización de modelos para su ejecución directamente en dispositivos móviles, sin necesidad de conectarse a servicios externos o *APIs*. Este paradigma, conocido como *on-device inference*, permite que el proceso de clasificación se realice íntegramente con los recursos del dispositivo, lo que resulta especialmente relevante en contextos con conectividad limitada, como en las comunidades indígenas a las que está orientado este proyecto.

La lucha contra la deforestación ilegal con *TensorFlow*

El trabajo, desarrollado por Google, mostrado en este artículo [13] demostró la viabilidad de ejecutar inferencias con modelos de reconocimiento de audio en dispositivos móviles de recursos limitados mediante *TensorFlow*. El caso de aplicación fue un trabajo para reducir la tala ilegal en el Amazonas. Primeramente se desarrolló un modelo capaz de distinguir entre sonidos habituales de la selva y sonidos asociados a la tala de árboles, seguido a esto el modelo se instaló en múltiples dispositivos interconectados distribuidos en distintas zonas de un área natural protegida, conformando así un sistema de alerta temprana para prevenir la deforestación.

Evaluación comparativa de modelos de aprendizaje profundo para la detección de objetos en dispositivos periféricos

Este estudio comparativo realizaro por Alqahtani *et al* [2] evaluaron el desempeño entre los modelos YOLO, EfficientDet y SSD MobilNet y los dispositivos Raspberry Pi 3, 5 y Jetson Ori Nano utilizando un modelo de clasificación de imágenes procesado en los frameworks TensorFlow Lite, Edge TPU, PyTorch y TensorRT.

Las métricas evaluadas incluyeron tamaño del modelo, tiempo de inferencia, consumo energético y precisión. Los resultados evidenciaron una compensación entre precisión, consumo de energía y velocidad: SSD_v1 fue el más rápido y eficiente energéticamente, aunque el menos preciso; Jetson Ori Nano resultó el dispositivo más veloz y eficiente para modelos YOLOv8 sin pérdida de precisión. La conversión de los modelos SSD y EfficientDet_Lite a TensorRT redujo su precisión, mientras que el acelerador Edge TPU mejoró el rendimiento de SSD y EfficientDet_Lite sin afectarla.

Este estudio demuestra que es posible obtener resultados satisfactorios en términos de rapidez y eficiencia energética, sin sacrificar la precisión, mediante el uso de modelos optimizados para dispositivos embebidos en futuros trabajos.

Un análisis comparativo exhaustivo de las bibliotecas de aprendizaje profundo en dispositivos móviles

En este trabajo comparativo, realizado por Zhang *et al*, [34] se desarrolló un benchmark automático referente al aprendizaje profundo en dispositivos móviles. Usando este benchmark automático se evaluó el desempeño de 6 bibliotecas de aprendizaje profundo usando 15 modelos distintos, entre ellos 10 de clasificación de imágenes, evaluándose en

11 dispositivos Android diferentes. Observando el rendimiento de Pytorch-M, MNN, TensorFlow Lite, NCNN, SNPE y MACE, se evidenció que ninguna biblioteca es óptima de forma universal para todos los modelos y dispositivos, por lo que la selección de alguna debe realizarse analizando caso por caso o incluso considerando la combinación de varias. Asimismo, se concluyó que la elección de la biblioteca puede tener un impacto mayor en el rendimiento de la inferencia incluso que el propio hardware utilizado.

Este tipo de trabajos representan un punto de partida sobre el cual basarnos para llevar los resultados de arquitecturas eficientes y bibliotecas adecuadas en el trabajo de reconocimiento de la lengua hablada a los entornos realistas donde se encuentra el valor social de una inferencia adecuada.

Capítulo 4

Metodología

Conjuntos de datos de audio

Los datos de audio en las lenguas Náhuatl, Maya y Zapoteco se recabarán en los siguientes meses por parte del proyecto 'Identificación automática de Lenguas indígenas para emergencias críticas'[1] el cual tiene como meta la cantidad de por lo menos 1000 clips de audio en cada lengua. Asimismo se complementará con registros ya existentes del INALI como lo son medios recabados en el tiempo por distintos proyectos anteriores, entre los cuales se encuentran películas, videos, prontuarios auditivos, etc. con contenido en estas tres lenguas.

Estos audios tendrán un preprocesamiento con el objetivo de asegurar que correspondan adecuadamente a cada lengua y que tengan la misma duración. Además, los audios originales se separarán y se crearán duplicados que mediante recortes automáticos, filtrado de frecuencias y manejo de la ecualización utilizando el software *Audacity*, estén libres de ruidos de fondo y sin secciones de audio con silencios. Como salida de este preprocesamiento se obtendrán los siguientes conjuntos de datos por cada lengua y cada formato de 3, 5 y 10 segundos:

- Corpus original
- Corpus sin silencios
- Corpus con filtrado de ruido
- Corpus sin silencios y con filtrado de ruido

Construcción de los modelos

Este trabajo contemplará la construcción y experimentación con modelos y arquitecturas individuales ya existentes así como el desarrollo de arquitecturas híbridas. Para la

[1]Esta tesis se enmarca en el Proyecto SECIHTI CBF-2025-G-368 Identificación automática de lenguas indígenas para emergencias críticas liderado por CentroGEO en colaboración con comunidades indígenas locales e instituciones como UADY, CEPIADET, INALI e IBERO.

construcción de los modelos individuales se considera el uso tanto de diferentes arquitecturas de redes neuronales, como de diferentes modelos preentrenados. Se emplearán las arquitecturas CNN, LSTM y TDNN, un modelo *x-vector* basado en TDNN y los modelos preentrenados *x-vector*, *Whisper* y *Wav2Vec*.

Los modelos se construyen a partir de las representaciones del audio obtenidas en la etapa de preprocesamiento, las cuales pueden corresponder a características acústicas o a espectrogramas, dependiendo del enfoque utilizado.

Se desarrollarán y utilizarán modelos que permiten extraer patrones relevantes del audio y realizar la clasificación de manera automática. Las arquitecturas de estos modelos usarán la composición usual de tres bloques principales: un bloque de extracción de características, encargado de procesar la entrada; un bloque de modelado, que captura dependencias temporales o espaciales; y un bloque de clasificación final.

Cada modelo se entrenará utilizando los datos disponibles, ajustando sus parámetros para minimizar una función de pérdida asociada a la tarea. Durante este proceso, se emplean técnicas de regularización y validación con el fin de evitar el sobreajuste y mejorar la capacidad de generalización.

Construcción de modelos híbridos

En este trabajo, se utilizará el modelo *x-vector* y los modelos preentrenados *Whisper* y *Wav2Vec* como extractores de características. Cada uno de estos modelos genera una representación distinta del mismo audio con el objetivo de aprovechar la información complementaria que cada uno aporta. Posteriormente, estas representaciones se procesan de manera independiente para obtener *embedding* a nivel de enunciado.

Una vez obtenidos los *embedding*, se evalúa su compatibilidad con las diferentes arquitecturas seleccionadas. A partir de ello, se exploran distintas estrategias de fusión para combinar las representaciones con el fin de obtener una representación conjunta más completa.

Este enfoque se plantea de manera experimental, evaluando múltiples combinaciones tanto de extractores de características como de métodos de fusión y clasificadores. La representación final resultante se utiliza como entrada de un clasificador, el cual puede orientarse a métodos tradicionales como SVM o KNN, así como a modelos de aprendizaje profundo.

Evaluación de modelos y optimizadores

Una vez construidos los modelos se realizará la evaluación de cada uno. Las métricas seleccionadas para representar el desempeño de los modelos con los diferentes conjuntos de datos y formas de optimización son:

- Tamaño del modelo en Mb
- Duración de la inferencia en frío en segundos
- Duración de la inferencia en no frío en segundos

- Tasa de precisión
- Tasa de exactitud
- Puntaje Recall
- Puntaje F1
- Tabla de confusión

Después de la evaluación de los modelos obtenidos de forma directa del entrenamiento en sus formas bases, se construirán modelos más eficientes para ambientes móviles utilizando los siguientes optimizadores:

- TensorFlow Lite
- Executorch
- NCNN
- MACE
- MNN

y se realizarán las evaluaciones siguiendo las mismas métricas definidas.

A partir de los resultados obtenidos se hará un análisis comparativo entre los diferentes modelos considerando tanto su desempeño en métricas de clasificación como su eficiencia computacional. Este análisis permitirá identificar patrones en el comportamiento de las arquitecturas frente a distintos tipos de preprocesamiento y duración de los audios.

Asimismo, se evaluará el impacto de las técnicas de optimización sobre la pérdida de precisión y la mejora en tiempos de inferencia y tamaño del modelo. Con base en estos resultados, se identificará el conjunto arquitectura-dataset con el mejor desempeño en un ambiente tradicional, así como el conjunto arquitectura-dataset-compresión más adecuado para su implementación en dispositivos móviles, priorizando un equilibrio entre precisión, eficiencia y viabilidad práctica.

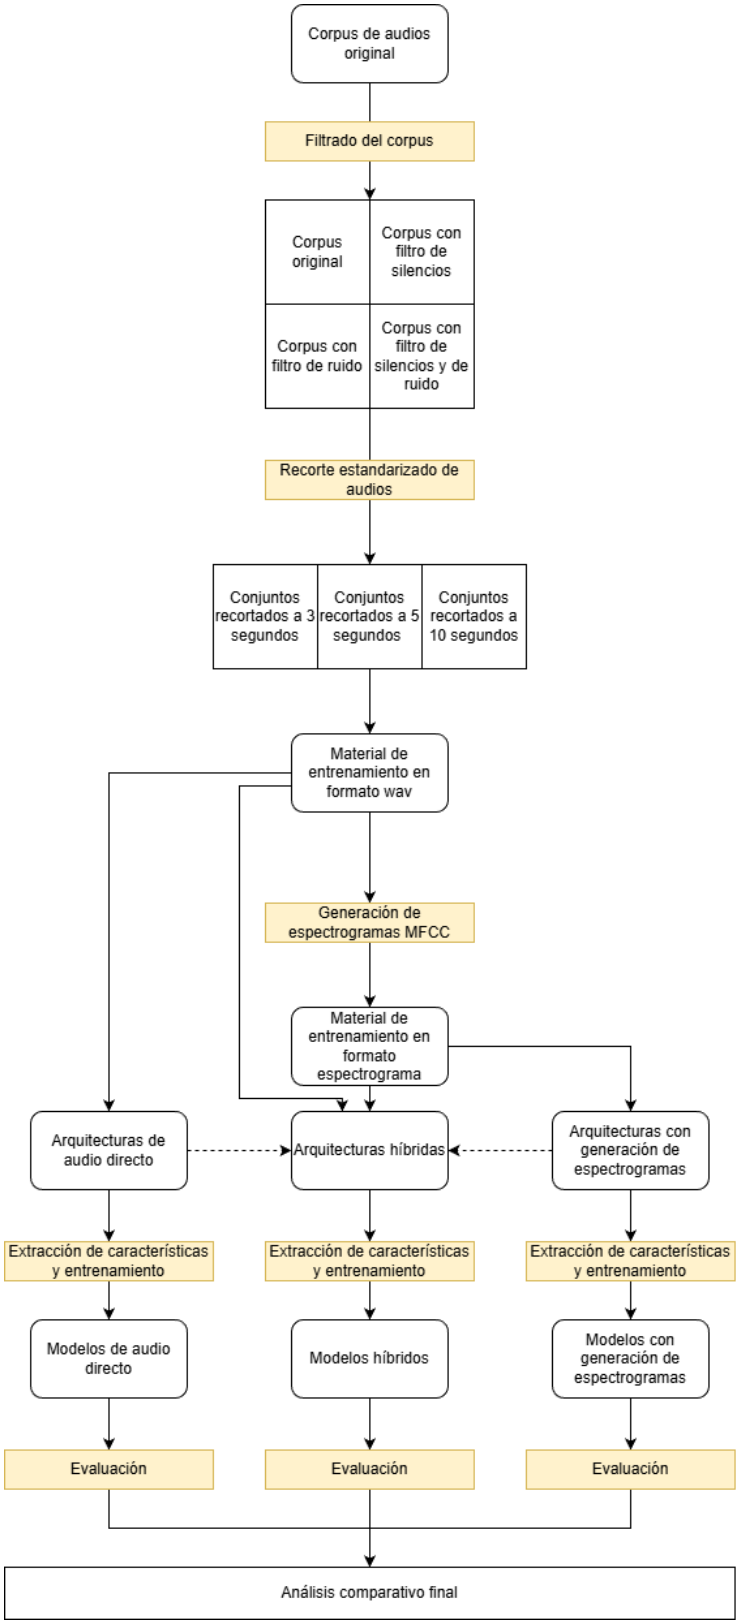


Figura 4.1: Flujo de trabajo.

Capítulo 5

Conclusiones

Este trabajo busca generar un impacto social positivo, al proponer una herramienta que pueda contribuir a mejorar el acceso a servicios públicos reduciendo las barreras lingüísticas que enfrentan las comunidades originarias en México. Se plantea el desarrollo de un sistema de identificación automática de lengua hablada para tres lenguas indígenas mexicanas: Náhuatl, Maya y Zapoteco mediante técnicas de aprendizaje profundo.

A partir de un análisis del contexto histórico, social y tecnológico, se identificó que la principal limitación en el desarrollo de modelos de aprendizaje automático para la clasificación de la lengua hablada, en este contexto, es la escasez de recursos digitales disponibles. Sin embargo, la revisión del estado del arte permitió observar que existen metodologías las cuales en su aplicación son capaces de mantener resultados favorables incluso en contextos de conjuntos de datos limitados.

La propuesta metodológica de este trabajo integra diferentes paradigmas para la clasificación de audio, enfocándose principalmente en modelos basados en espectrogramas (CNN, LSTM), pero también en modelos de procesamiento directo de señal de audio (Wav2Vec) y arquitecturas híbridas. Asimismo, se plantea una evaluación que considera no solo métricas de precisión, sino también información relevante para su implementación en entornos reales, como el tamaño del modelo y el tiempo de inferencia. De igual manera se considera en la evaluación la aplicabilidad en dispositivos móviles mediante técnicas de optimización como TensorFlow Lite y otras bibliotecas especializadas, con el objetivo de brindar un panorama más amplio para una futura implementación en contextos con conectividad limitada como lo suelen ser las comunidades originarias de México.

Plan de trabajo

El presente trabajo tendrá una duración de 12 meses en los cuales se realizarán las siguientes actividades siguiendo el cronograma descrito en la Figura 5.1:

Primer mes

Se realizará el preprocesamiento de los audios obtenidos organizándolos en una estructura que siga la lengua, duración y características. Se configurará el ambiente de trabajo

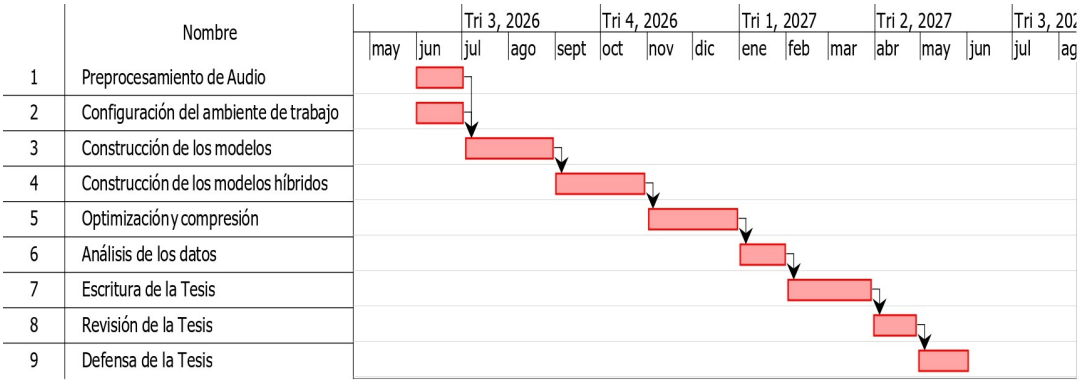


Figura 5.1: Cronograma de actividades

.

óptimo para inteligencia artificial en clasificación de audio usando herramientas en la nube para el almacenamiento, procesado y construcción.

Segundo y tercer mes

Se construirán los modelos individuales combinando los diferentes conjuntos de audios con las 4 arquitecturas elegidas y realizando las evaluaciones definidas.

Cuarto y quinto mes

Se desarrollarán los modelos híbridos que fusionan las diferentes arquitecturas de igual forma combinándolas con los diferentes conjuntos de audio y realizando las evaluaciones definidas.

Sexto y séptimo mes

Con los modelos individuales e híbridos construidos se realizará el proceso de optimización y compresión con las diferentes tecnologías definidas y se realizarán las mismas evaluaciones con los modelos resultantes.

Octavo mes

Se realizará un análisis de todos los datos obtenidos identificando qué conjuntos de audio, qué arquitecturas y qué optimizadores obtuvieron los mejores resultados para identificar el modelo con mejor puntuación y el modelo con mejor desempeño en un entorno realista.

Noveno y décimo mes

Con los modelos construídos y el análisis realizado se redactarán los contenidos de la tesis describiendo los resultados finales del trabajo.

Onceavo y doceavo mes

Se realizarán ciclos de revisiones conjuntas y correcciones de errores de la tesis para asegurar una redacción y un análisis correctos y completos.

Finales del doceavo mes

Proceso de defensa de la tesis.

Bibliografía

[1] Acción Ciudadana Frente a la Pobreza. *Concentra pobreza población indígena y rural; Economía Social, vía para superarla*. Comunicado 11/2025. Consultado el 7 de agosto de 2026. Acción Ciudadana Frente a la Pobreza. Sep. de 2025. URL: https://www.frentealapobreza.mx/post/com-2512.

[2] Daghash Alqahtani, Aamir Cheema y Adel Toosi. *Benchmarking Deep Learning Models for Object Detection on Edge Computing Devices*. Sep. de 2024. DOI: 10.48550/arXiv.2409.16808.

[3] Andrés Morales Arciniegas. *Pueblos indígenas hacia el futuro desde el presente digital*. Columna en *Milenio* (Opinión). Consultado el 19 Febrero 2026. 8 de ago. de 2025. URL: https://www.milenio.com/opinion/andres-morales-arciniegas/columna-invitada-de-andres-morales-arciniegas/pueblos-indigenas-hacia-el-futuro-desde-el-presente-digital.

[4] Asociación Mexicana de Lingüística Aplicada. *Lenguas zapotecanas*. AMLA. URL: https://amla.org.mx/lenguas-zapotecanas/ (visitado 05-03-2026).

[5] Alexei Baevski, Yuhao Zhou, Abdelrahman Mohamed y Michael Auli. «wav2vec 2.0: A framework for self-supervised learning of speech representations». En: *Advances in neural information processing systems* 33 (2020), págs. 12449-12460.

[6] Jean Carlos Buenfil Aguilar, Silvia Fernández-Sabido, Jorge Reyes-Magaña, Luis Basto-Díaz, Luis Fernando Curi-Quintal y Oscar Gerardo Sánchez Siordia. «Bridging the Language Gap: AI-Powered Identification of Yucatec Maya and Spanish for Emergency Response». En: *Artificial Intelligence – COMIA 2025*. Ed. por Lourdes Martínez-Villaseñor, Bella Martínez-Seis y Obdulia Pichardo. Cham: Springer Nature Switzerland, 2025, págs. 105-116. ISBN: 978-3-031-97907-1.

[7] Ernesto Arana Bustamante. *Principales barreras de acceso a la salud para las poblaciones indígenas de México*. Consultado el 26 de febrero de 2026. Revista ESPM. 2025. URL: https://revista.espm.mx/nota-principales-barreras-de-acceso-a-la-salud-para-las-poblaciones-indigenas-de-mexico-1.

[8] Carlos Eduardo Tec Cahun, Jonathan David Chi Quiñones, Silvia Fernández-Sabido y Alina Dianela Ballote Blanco. *Modelos ligeros de inteligencia artificial para clasificación de audios Maya-Español*. Ponencia presentada en el 5o Congreso Internacional de Procesamiento de Lenguaje Natural para las Lenguas Indígenas, Universidad Michoacana de San Nicolás de Hidalgo, Morelia, Michoacán, México, 15–17 de octubre de 2025. 2025.

[9] Ürsula Camba Ludlow. *Los españoles genocidas querían exterminar a los pueblos indígenas*. Consultado el 7 de agosto de 2026. Relatos e Historias en México / Editorial Raíces, 2023. URL: https://relatosehistorias.mx/nuestras-historias/los-espanoles-genocidas-querian-exterminar-los-pueblos-indigenas.

[10] Himanish Shekhar Das y Pinki Roy. «Chapter 5 - A Deep Dive Into Deep Learning Techniques for Solving Spoken Language Identification Problems». En: *Intelligent Speech Signal Processing*. Ed. por Nilanjan Dey. Academic Press, 2019, págs. 81-100. ISBN: 978-0-12-818130-0. DOI: https://doi.org/10.1016/B978-0-12-818130-0.00005-2. URL: https://www.sciencedirect.com/science/article/pii/B9780128181300000052.

[11] Edomex Al Día. *La brecha digital en las comunidades indígenas es un desafío significativo para las instituciones*. Consultado el 19 Febrero 2026. 7 de ago. de 2023. URL: https://edomexaldia.com/la-brecha-digital-en-las-comunidades-indigenas-es-un-desafio-significativo-para-las-instituciones/.

[12] Augusto Gayubas. *Lengua maya*. Enciclopedia Concepto. Mayo de 2025. URL: https://concepto.de/lengua-maya/ (visitado 08-01-2026).

[13] Google. *The fight against illegal deforestation with TensorFlow*. Google Blog. Mar. de 2018. URL: https://blog.google/innovation-and-ai/products/fight-against-illegal-deforestation-tensorflow/ (visitado 13-03-2026).

[14] Panikos Heracleous, Keiji Takai, Keiji Yasuda, Yasser Mohammad y Akio Yoneyama. «Comparative Study on Spoken Language Identification Based on Deep Learning». En: *2018 26th European Signal Processing Conference (EUSIPCO)*. IEEE, sep. de 2018, págs. 2265-2269. DOI: 10.23919/eusipco.2018.8553347.

[15] IBM. *¿Qué es el deep learning?* IBM Think. 2024. URL: https://www.ibm.com/mx-es/think/topics/deep-learning (visitado 12-03-2026).

[16] IMSS-Bienestar. *Mapa de Alta Resolución: Infraestructura del Programa IMSS-Bienestar*. Documento cartográfico oficial. Información oficial 2025 basada en unidades en operación al cierre 2024 (CLUES). Instituto Mexicano del Seguro Social, 2025. URL: https://www.imss.gob.mx/sites/all/statics/imssBienestar/infraestructura/MapaAltaResolucion.pdf.

[17] Instituto Nacional de Estadística y Geografía (INEGI). *Estadísticas a propósito del Día Internacional de los Pueblos Indígenas*. Comunicado de prensa Núm. 430/22. INEGI, México. Ago. de 2022. URL: https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2022/EAP_PueblosInd22.pdf.

[18] Instituto Nacional de Lenguas Indígenas. *Prontuarios de frases de cortesía en lenguas indígenas nacionales*. INALI. 2026. URL: https://site.inali.gob.mx/Micrositios/Prontuarios/index.html/ (visitado 12-03-2026).

[19] Instituto Nacional de Lenguas Indígenas (INALI). *Catálogo de las Lenguas Indígenas Nacionales: Variantes Lingüísticas de México con sus Autodenominaciones y Referencias Geoestadísticas*. Consulta PDF del Catálogo completo. Instituto Nacional de Lenguas Indígenas (INALI). 2008. URL: https://www.inali.gob.mx/pdf/CLIN_completo.pdf.

[20] *Ley General de Derechos Lingüísticos de los Pueblos Indígenas*. Última reforma publicada en el Diario Oficial de la Federación el 18 de octubre de 2023. México: Instituto Nacional de Lenguas Indígenas (INALI), 2003. URL: https://site.inali.gob.mx/Micrositios/LGDLPI/ (visitado 15-05-2024).

[21] «Literacy in Colonial Mesoamerica». En: *Mesoamerican Voices: Native Language Writings from Colonial Mexico, Yucatan, and Guatemala*. Cambridge University Press, 2005, págs. 11-20.

[22] Diario Marca. *Barreras lingüísticas impiden el acceso equitativo a un juicio justo*. Consultado el 26 de febrero de 2026. Diario Marca. Feb. de 2026. URL: https://www.diariomarca.com.mx/2026/02/barreras-linguisticas-impiden-el-acceso-equitativo-a-un-juicio-justo/.

[23] Himadri Mukherjee, Subhankar Ghosh, Shibaprasad Sen, Obaidullah Sk Md, K. C. Santosh, Santanu Phadikar y Kaushik Roy. «Deep learning for spoken language identification: Can we visualize speech signal patterns?» En: *Neural Computing and Applications* 31 (2019), págs. 8483-8501. DOI: 10.1007/s00521-019-04468-3. URL: https://doi.org/10.1007/s00521-019-04468-3.

[24] Joshua Noble. *What is Long Short-Term Memory (LSTM)?* Accessed: 2026-06-15. n.d. URL: https://www.ibm.com/think/topics/lstm.

[25] Omar Páramo y Myriam Núñez. *La Conquista provocó la muerte de casi el 90 % de los indígenas*. Consultado el 7 de agosto de 2026. Universidad Nacional Autónoma de México (UNAM) / UNAM Global. Nov. de 2019. URL: https://unamglobal.unam.mx/global_revista/la-conquista-provoco-la-muerte-de-casi-el-90-de-los-indigenas/.

[26] Sachin Prabhu, Dhananjaya V, Shilpa Kamath, Muralikrishna H, K Krishna Prakasha y Dileep Aroor Dinesh. «Spoken language identification system for detecting coastal karnataka languages using transfer learning and multi-view learning». En: *Engineering Research Express* 8.1 (ene. de 2026), pág. 015203. DOI: 10.1088/2631-8695/ae2fac. URL: https://doi.org/10.1088/2631-8695/ae2fac.

[27] Diego Prieto Hernández, ed. *México: grandeza y diversidad*. Con la colaboración de Guillermo Acosta Ochoa [y 22 más]. Instituto Nacional de Antropología e Historia ; Fondo de Cultura Económica, 2021. ISBN: 978-607-539-498-5.

[28] Carolina Sánchez García. *Desigualdad en poblaciones indígenas y afromexicanas. Dimensiones múltiples en la configuración de la desigualdad social*. Consultado el 7 de agosto de 2026. Revista UNAM Internacional, Universidad Nacional Autónoma de México (UNAM). Dic. de 2025. URL: https://revista.unaminternacional.unam.mx/nota/11/desigualdad-en-poblaciones-indigenas-y-afromexicanas-dimensiones-multiples-en-la-configuracion-de-la-desigualdad-social.

[29] Secretaría de Salud, Gobierno de México. *Las barreras culturales en los servicios de salud: Su papel en el acceso de la población usuaria a los servicios*. Documento PDF consultado el 26 de febrero de 2026. Secretaría de Salud. URL: https://www.salud.gob.mx/unidades/cdi/documentos/barreras_culturales.pdf.

[30] Gundeep Singh, Sahil Sharma, Vijay Kumar, Manjit Kaur, Mohammed Baz y Mehedi Masud. «Spoken Language Identification Using Deep Learning». En: *Computational Intelligence and Neuroscience* 2021.1 (2021), pág. 5123671. DOI: https://doi.org/10.1155/2021/5123671. eprint: https://onlinelibrary.wiley.com/doi/pdf/10.1155/2021/5123671. URL: https://onlinelibrary.wiley.com/doi/abs/10.1155/2021/5123671.

[31] Thelma D. Sullivan. *Compendio de la gramática náhuatl*. 3.ª ed. Serie Cultura Náhuatl. Monografías, 18. México: Universidad Nacional Autónoma de México, Instituto de Investigaciones Históricas, 2014. ISBN: 978-607-02-5459-8. URL: https://historicas.unam.mx/publicaciones/publicadigital/libros/gramatica/cgn_intro.pdf.

[32] Enrique Vela. «Áreas culturales: Oasisamérica, Aridamérica y Mesoamérica». En: *Arqueología Mexicana* Especial 82 (oct. de 2018). Edición especial "25 años de Arqueología Mexicana. Nuestra historia", págs. 28-29.

[33] Panji Wijonarko y Amalia Zahra. «Spoken language identification on 4 Indonesian local languages using deep learning». En: *Bulletin of Electrical Engineering and Informatics* 11.6 (2022). Accedido el 7 de agosto de 2026, págs. 3288-3293. ISSN: 2302-9285. DOI: 10.11591/eei.v11i6.4166. URL: https://beei.org/index.php/EEI/article/view/4166.

[34] Qiyang Zhang, Xiang Li, Xiangying Che, Xiao Ma, Ao Zhou, Mengwei Xu, Shangguang Wang, Yun Ma y Xuanzhe Liu. *Benchmarking of DL Libraries and Models on Mobile Devices*. 2022. arXiv: 2202.06512 [cs.LG]. URL: https://arxiv.org/abs/2202.06512.