Universidad Intercultural Maya

Ser en el mundo, ser nosotros • Wíinikil yóok'ol kaab, jée bixo'one' • To be in the world, to be ourselves

TÍTULO

MODELOS LIGEROS DE REDES NEURONALES CONVOLUCIONALES PARA CLASIFICACIÓN DE ESPECTROGRAMAS DE AUDIO EN ENTORNOS MÉDICOS BILINGÜES (MAYA-ESPAÑOL)

TESIS

Para obtener el Título de:
Ingeniero en Tecnologías de Información y Comunicación

PRESENTA

Carlos Eduardo Tec Cahun
Jonathan David Chi Quiñones

José María Morelos, Quintana Roo, México

31 – 08 – 2025

Universidad Intercultural Maya de Quintana Roo

Ser en el mundo, ser nosotros • Wíinikil yóok'ol kaab, jée bixo'one' • To be in the world, to be ourselves

TÍTULO

Modelos ligeros de inteligencia artificial para la clasificación de audios maya-español.

TESIS

PRESENTADA POR:

Carlos Eduardo Tec Cahun
Jonathan David Chi Quiñones

Para obtener el Título de:
Ingeniero en Tecnologías de Información y Comunicación

Elaborada bajo la supervisión y aprobación del Comité siguiente:

Director (a): Silvia Fidelina Fernández Sabido

Nombre y firma

Asesor (a): Alina Dianela Ballote Blanco

Nombre y firma

Asesor (a): Angel Abraham Ucan Dzul

Nombre y firma

José María Morelos, Quintana Roo, México

Fecha

02 – 10 - 2025

1

Contenido

UNIDAD I. PROYECTO DE INVESTIGACIÓN 5

1.1. INTRODUCCIÓN 5

1.2. PLANTEAMIENTO DEL PROBLEMA Y DELIMITACIÓN DEL OBJETO DE ESTUDIO 7

1.3. JUSTIFICACIÓN 11

1.4. OBJETIVOS 12

1.4.1. Objetivo general 12

1.4.2. Objetivos específicos 12

1.5. PREGUNTAS DE INVESTIGACIÓN O HIPÓTESIS 13

UNIDAD II. MARCO TEÓRICO 13

2.1. ANTECEDENTES DE LA INVESTIGACIÓN 13

2.1.1 Definición de Procesamiento de Lenguaje Natural 13

2.1.2 Modelos de Procesamiento de Lenguaje Natural 14

2.1.2 Modelos de Aprendizaje Profundo 16

2.1.3 Modelos Transformers 20

2.1.4 Modelos usados en el maya 21

2.1.5 Modelos de PLN y aprendizaje profundo en el área médica 24

2.1.6 Lenguas indígenas 26

2.2. DEFINICIÓN DE TÉRMINOS BÁSICOS 28

2.2.1 Lenguaje Natural 28

2.2.2 Procesamiento de Lenguaje Natural *28*

2.2.3 Corpus *29*

2.2.4 Acústica *30*

2.2.5 Pratt *31*

UNIDAD III. MÉTODO **32**

3.1 RECOLECCIÓN Y PREPARACIÓN DE DATOS 32

3.1.1 Fuentes de datos *32*

3.1.2 Características del dataset *34*

3.2 GENERACIÓN DE ESPECTROGRAMAS 35

3.2.1 Representación de audio como imágenes *35*

3.3 ARQUITECTURA DE LA RED NEURONAL CONVOLUCIONAL 36

3.3.1 Red neuronal convolucional *36*

3.2. TRANSFERENCIA DE CONOCIMIENTO 36

3.3. PROCESO IMPLEMENTADO 37

3.3.1. Modelos elegidos *37*

3.3.2 Diseño de la arquitectura *38*

3.3.3 Hiperparámetros *40*

3.4 ENTRENAMIENTO DEL MODELO 40

3.4.1 División del dataset *40*

3.4.2 Entrenamiento *42*

3.4.3. Monitoreo del entrenamiento *43*

3.5 EVALUACIÓN DEL MODELO 45

3.5.1 Métricas de evaluación *45*

3.6 BITÁCORA DE EXPERIMENTOS 46

3.6.1. Herramientas *46*

3.7 DIAGRAMAS DEL PROCESO 49

UNIDAD IV. ANÁLISIS E INTERPRETACIÓN DE RESULTADOS 52

4.1 ENTRENAMIENTO INICIAL 52

4.2 ENTRENAMIENTO CON DATA AUGMENTATION 56

UNIDAD V. CONCLUSIONES 60

5.1 RESULTADOS MÁS RELEVANTES 60

5.2 CONCLUSIONES GENERALES 61

5.3 LIMITACIONES 62

5.4 RECOMENDACIONES FINALES 64

UNIDAD VI. BIBLIOGRAFÍA Y ANEXOS 65

6.1. REFERENCIAS 65

UNIDAD I. PROYECTO DE INVESTIGACIÓN

1.1. INTRODUCCIÓN

En un país como México, que se caracteriza por una gran diversidad lingüística, las lenguas indígenas ocupan un lugar importante en la identidad y transmisión de saberes ancestrales. En este contexto, la lengua Maya, una de las más habladas en el país con más de 800,000 hablantes según el INEGI (2020), enfrenta diversos desafíos, tanto en el ámbito tecnológico como en el educativo y de la salud, ya que ha sido desplazada por lenguas como el español o el inglés en la actualidad.

Por ello, este problema abre la posibilidad de rescatar la lengua m aya en un ámbito que ha sido pocas veces explorado, siendo el ámbito médico uno de ellos. Así, desarrollar recursos tecnológicos que integren lenguas originarias, en especial en contextos de inteligencia artificial culturalmente pertinente (UNESCO, 2023), lo que ha sido una de las principales razones de elaborar este trabajo, el cual busca tener un peso en la sociedad. Además, a la par del crecimiento del Procesamiento de Lenguaje Natural (PLN) como campo interdisciplinario que permite a las máquinas interpretar y generar lenguaje humano (Gelbukh, 2010), ha surgido un interés creciente por desarrollar recursos tecnológicos que integren lenguas originarias como la lengua maya.

En este sentido, este trabajo resulta importante en situaciones donde la comunicación entre profesionales de la salud y pacientes se ve limitada por cuestiones de la lengua. Por ejemplo, cuando una persona que solo habla maya acude al médico, muchas veces no puede expresar sus síntomas en español, lo que dificulta el diagnóstico y la atención si no hay un intérprete. Por ello, la creación de un corpus paralelo de maya - español, el análisis acústico, creación de espectrogramas y la aplicación de modelos computacionales se convierten en

herramientas clave para proponer soluciones que respeten tanto la lengua como el contexto sociocultural de los hablantes (UNESCO, 2023).

La atención medica es un derecho que se ve afectado, las barreras lingüísticas son un problema que se presenta en el día a día de personas de comunidades que se deben desplazar para buscar atención médica, y poder tener acceso a información clara. Diversos estudios han demostrado que las barreras lingüísticas en contextos de atención médica incrementan la probabilidad de diagnósticos erróneos, dificultan la comprensión de los tratamientos y generan desconfianza entre el personal de salud y los pacientes (Flores, 2006).

Desde el ámbito del PLN, el entrenamiento de CNN es clave para habilitar tecnologías como asistentes virtuales o traductores automáticos entre maya y español. Sin embargo, los avances en estas áreas han sido escasos. Iniciativas recientes como MayanV (Lou et al., 2024), centradas en el modelado neuronal de variantes mayas para traducción automática, evidencian tanto el potencial como la necesidad de ampliar este tipo de tecnologías hacia nuevas áreas como el de la salud. Además, modelos como los desarrollados por Tyers y Richardson (2021) para el análisis morfosintáctico del k'iche' confirman la viabilidad técnica de aplicar modelos de PLN en lenguas originarias, aunque aún quedan desafíos como la escasez de datos, la variación dialectal y la necesidad de adaptación de significado.

A nivel metodológico, el uso de herramientas como Praat para el análisis acústico en lengua maya permitirá capturar y representar de forma precisa las características fonéticas de términos médicos, lo que puede contribuir significativamente a la construcción de interfaces más precisas en sistemas de diálogo o reconocimiento de voz (Boersma & Weenink, 2023). Además, el entrenamiento de modelos sobre corpus médicos permitirá que estos modelos aprendan

términos que son importantes en el contexto cultural o lingüístico especifico, por ejemplo, en la lengua maya existen al menos tres formas distintas de expresar un dolor de estómago, *Chi'ibal, k'i'inam,* y *yaaj*. Conocer estos términos resulta importante para un médico, ya que le permite comprender mejor lo que el paciente siente y, en consecuencia, ofrecer un tratamiento adecuado. Para este fin, el presente estudio emplea CNN con tres arquitecturas MobileNetV2, MobileNetV3 y EfficientNetB0, que fueron entrenadas con imágenes de espectrogramas generadas a partir de audios en maya. Esta propuesta busca contribuir a la inclusión digital y lingüística de los pueblos mayas mediante el diseño de recursos especializados en PLN, permitiendo sentar las bases para que las comunidades puedan acceder a modelos de CNN entrenados para detectar el idioma, favoreciendo una relación entre la tecnología y la salud.

La presente investigación se organiza en cinco capítulos: el primero plantea el problema, los objetivos y la justificación; el segundo presenta el marco teórico y la revisión de literatura; el tercero describe la metodología; el cuarto expone los resultados del modelo; y el quinto ofrece las conclusiones, limitaciones y recomendaciones.

1.2. PLANTEAMIENTO DEL PROBLEMA Y DELIMITACIÓN DEL OBJETO DE ESTUDIO

En México existen 68 lenguas indígenas nacionales, y entre ellas el maya yucateco es una de las más habladas, con más de 800,000 hablantes, sobre todo en la península de Yucatán (INEGI, 2020). Sin embargo, a pesar de la cantidad de personas que la utilizan en su vida diaria, la lengua maya sigue estando olvidada en los espacios digitales. Esto se nota aún más en el desarrollo de nuevas tecnologías relacionadas con el lenguaje, como la traducción automática, el reconocimiento de voz o, en este caso, el uso de redes neuronales para trabajar con el idioma.

Esta falta de presencia digital se vuelve un problema serio en el ámbito de la salud, ya que la comunicación entre paciente y médico debe ser clara y precisa para poder dar un buen tratamiento. Cuando no existe un traductor o un recurso tecnológico que facilite el entendimiento, muchas personas maya hablantes enfrentan dificultades para explicar sus síntomas, lo que afecta directamente la calidad de la atención médica que reciben.

El acceso limitado de las comunidades maya hablantes a información médica en su lengua materna representa un problema que impacta en su bienestar. Esta situación no es exclusiva del pueblo maya: en comunidades indígenas como la wayuu, en Colombia, también se han identificado barreras culturales y lingüísticas que dificultan la atención médica, lo que ha llevado a incorporar interpretes bilingües, que ayudan a la comunicación entre las personas que no hablan el español y alguna lengua indígena, logrando una atención decente por parte de los médicos (Patiño-Londoño et al., 2016). Estas situaciones demuestran como las nuevas estrategias culturales pueden ser clave para garantizar el derecho a la salud a comunidades aisladas o marginadas, lo que refuerza a adoptar nuevas estrategias con enfoque a la salud en comunidades mayas.

Uno de los principales obstáculos para el desarrollo de sistemas de PLN en lenguas originarias es la falta de corpus lingüísticos adecuados. Un corpus paralelo (conformado por textos o audios alineados entre dos lenguas) es esencial para entrenar modelos, ya que el extenso vocabulario, así como las variantes lingüísticas de las regiones son muchas. Actualmente, no se dispone de un corpus paralelo maya-Español especializado en salud, lo que impide el desarrollo de herramientas de PLN orientadas a mejorar la comunicación médico-paciente en contextos interculturales. En algunas regiones del país, comunidades aisladas se transportan de emergencia

a centros médicos, y entre prisa y desesperación, las personas tratan de explicar lo que les sucede a ellos o al familiar en situación de gravedad. Es esencial que, si el personal de salud no habla la lengua de los pacientes, consiga a un intérprete rápidamente, pero muchas veces ni siquiera sabe de qué lengua se trata, ya que algunas regiones del país tienen más de 3 variantes de lenguas indígenas, llevando a perdida humanas en casos extremos.

La creación de dicho corpus, y el entrenamiento de modelos de identificación de lenguas, permitiría avanzar en tareas como la traducción automática de diagnósticos o la interpretación oral de síntomas, facilitando la comunicación entre médicos y pacientes. Aunque este tipo de tecnología ya se ha implementado en el ámbito medico con agentes conversacionales para mejorar la atención médica, han sido en espacios privados y usando lenguas mayoritarias como el Español o inglés. (Guanoluisa, Chicaiza & Avalos, 2021). Esto refleja la necesidad urgente de adaptar estas tecnologías a contextos interculturales y lenguas originarias, donde aún no se cuenta con recursos lingüísticos ni modelos adecuados.

Además, trabajar con una lengua indígena no es solo un reto técnico, también es una responsabilidad cultural y ética. Diversos organismos internacionales han señalado que las comunidades deben participar activamente en la creación de materiales y herramientas digitales, ya que son ellas quienes poseen y transmiten el conocimiento (UNESCO, 2023). En este sentido, el corpus paralelo Maya-Español que usamos no es únicamente una recopilación de datos, sino un reflejo de la voz de la propia comunidad, que compartió su conocimiento para que pueda ser valorado y utilizado en nuevos espacios.

Este proyecto se propone trabajar principalmente con el corpus Maasab[1] conformado por aproximadamente 3,000 audios en Maya y Español, provenientes de las obras Manual de comunicación para médicos (Martín & Briceño, 2013) y *U áanalte'il u tsikbalil ts'aak* (Manual de frases médicas) (Castillo Tzec, 2013), grabados por estudiantes de la UIMQROO en 2022, alineados en Maya y Español durante esta tesis. Este recurso, más otros encontrados en internet, será empleado para entrenar modelos de PLN, en este caso CNN con arquitecturas ligeras. El corpus contiene temas médicos (síntomas, tratamientos comunes), así como situaciones de la vida cotidiana, y utilizará muestras simuladas con fines de entrenamiento computacional.

Geográficamente, el estudio se centrará en comunidades Maya hablantes del estado de Quintana Roo, en el centro del estado, José María Morelos, donde existe un rezago en el acceso a herramientas digitales en lengua indígena. Temporalmente, el proyecto se desarrollará en el periodo febrero - agosto 2025, con etapas de separación de audios, base de datos de los audios, entrenamiento del modelo con CNN. El enfoque será interdisciplinario, integrando conocimientos de lingüística, PLN, ciencias de la computación, salud pública y participación comunitaria.

Este trabajo busca responder a la pregunta: ¿De qué manera la evaluación de modelos ligeros de CNN puede contribuir al desarrollo de herramientas tecnológicas viables para el apoyo a la comunicación en entornos de salud de comunidades Maya hablantes, utilizando espectrogramas derivados de un corpus de audio médico bilingüe? La solución a esta problemática representa no solo una innovación en el campo del PLN, sino también un paso hacia el acceso del área de la salud para comunidades Maya hablantes.

[1] https://sites.google.com/view/maasabmakachi/inicio?authuser=1&read_current=1

1.3. JUSTIFICACIÓN

La presente investigación surge de la necesidad de atender dos problemas que podemos observar en el país: por un lado, la escasa disponibilidad de tecnologías aplicadas a las lenguas originarias; y por otro, la falta de herramientas en los servicios de la salud en comunidades indígenas. En México, aproximadamente 7.36 millones de personas hablan alguna lengua indígena, de las cuales más de 800,000 son hablantes de Maya yucateco, concentrados principalmente en la península de Yucatán (INEGI, 2020). A pesar de la alta presencia del idioma Maya, las tecnologías desarrolladas para el PLN han priorizado idiomas que son más usados, como el inglés y el Español, dejando en desventaja tecnológica a muchas lenguas indígenas (García, Mager & Oncevay, 2021).

Esta situación tiene implicaciones prácticas y sociales importantes. Diversos estudios han demostrado que durante una atención medica donde dos individuos no hablan la misma lengua pueden afectar negativamente la calidad de la atención, generar desinformación sobre tratamientos y profundizar la desconfianza hacia los servicios de salud (Flores, 2006). En este sentido, generar recursos como bases de datos para tener un corpus oral que incluyan frases comunes en contextos médicos (síntomas, diagnósticos y tratamientos básicos), constituye un primer paso hacia el desarrollo de soluciones que mejoren la comunicación entre personal médico y pacientes hablantes de lengua Maya.

El presente trabajo no tiene como objetivo directo la creación de una herramienta funcional, sino que busca sentar las bases experimentales para futuras aplicaciones. A través del uso de CNN , en combinación con espectrogramas derivados de audios en lengua Maya, se analiza la viabilidad de modelos ligeros (que requieren poco poder de cómputo) como

MobileNetV2, MobileNetV3 y EfficientNetB0 para el reconocimiento de patrones en frases relacionadas con la salud. Aunque el corpus trabajado se usa un conjunto inicial de frases médicas básicas, así como frases de la vida cotidiana, este enfoque permite explorar las posibilidades de clasificación y comprensión automática del lenguaje oral Maya, con la intención de que estos hallazgos puedan ser utilizados en futuros desarrollos tecnológicos.

Este estudio también aporta al ámbito académico, al tratarse, de un trabajo pionero en el ámbito del PLN con el uso de CNN que aplica modelos de aprendizaje profundo a corpus sonoros en lengua Maya. Por ello, representa un aporte cualitativo para investigadores en PLN, lenguas indígenas y tecnologías inclusivas, abriendo camino para proyectos similares en otras lenguas originarias del país.

1.4. OBJETIVOS

1.4.1. Objetivo general

Evaluar el rendimiento de modelos ligeros de redes neuronales convolucionales en la clasificación de espectrogramas a partir de corpus paralelos de audios Maya-Español, para identificar la arquitectura más viable para el reconocimiento de patrones de audio de frases en lengua Maya para el desarrollo de futuras herramientas de apoyo a la comunicación intercultural en entornos de salud.

1.4.2. Objetivos específicos

- Alinear audios en Maya con su traducción correspondiente en español
- Generar espectrogramas de los audios Maya y español

- Entrenar modelos ligeros de redes convolucionales para que aprendan a identificar cada lengua
- Evaluar el rendimiento de los modelos ligeros entrenados
- Determinar la viabilidad de su implementación como base de herramientas tecnológicas de apoyo

1.5. PREGUNTAS DE INVESTIGACIÓN O HIPÓTESIS

¿De qué manera la evaluación de modelos ligeros de Redes Neuronales Convolucionales (CNN) puede contribuir al desarrollo de herramientas tecnológicas viables para el apoyo a la comunicación en entornos de salud de comunidades Maya hablantes, utilizando espectrogramas derivados de un corpus de audio médico bilingüe?

UNIDAD II. MARCO TEÓRICO

2.1. ANTECEDENTES DE LA INVESTIGACIÓN

2.1.1 Definición de Procesamiento de Lenguaje Natural

El Procesamiento de Lenguaje Natural (PLN) es un campo interdisciplinario de la inteligencia artificial que busca que las computadoras comprendan, interpreten, generen y manipulen el lenguaje humano de forma automática, esto a diferencia de los sistemas que procesan únicamente secuencias de caracteres o sonidos. El PLN tiene como objetivo principal entender la información comunicada, es decir, el significado y la intención del lenguaje que se le presenta. Gelbukh, A. (2010) lo describe como la capacidad de una máquina para procesar no solo letras o sonidos, sino el contenido semántico del mensaje, lo que permite que las tecnologías de PLN puedan realizar tareas como la traducción automática, la generación de resúmenes, la

respuesta a preguntas o incluso la clasificación y agrupación de documentos, facilitando un manejo más eficiente del conocimiento humano.

Desde una perspectiva técnica, el PLN aborda distintos niveles de análisis del lenguaje: desde el léxico (identificación de palabras), el sintáctico (estructura gramatical), el semántico (significado), hasta el pragmático y contextual (intención comunicativa según el contexto) Manrique-Losada, B. (2015). Esta complejidad se ve reflejada en los retos que enfrentan los sistemas al interpretar correctamente ambigüedades, sinónimos comunes en el lenguaje natural.

Además, en el contexto de la ingeniería y la inteligencia artificial, el PLN se apoya actualmente en modelos avanzados como Transformers, GPT-3, o BERT, que emplean redes neuronales profundas para entender y generar texto de manera coherente. Estos modelos han revolucionado las aplicaciones del PLN, permitiendo su uso en chatbots, asistentes virtuales, motores de búsqueda semántica y traducción automática neuronal

El PLN representa un puente entre la comunicación humana y las capacidades computacionales, siendo clave para el desarrollo de tecnologías accesibles, inclusivas y contextualizadas. Su aplicación en áreas especializadas como la medicina y las lenguas indígenas (como se plantea en esta investigación) permite desarrollar herramientas que no solo facilitan el acceso a la información, sino que también contribuyen a la preservación lingüística y al fortalecimiento del derecho a la salud.

2.1.2 Modelos de Procesamiento de Lenguaje Natural

Modelos probabilísticos

Los modelos probabilísticos en PLN se fundamentan en el análisis de datos lingüísticos estructurados en corpus, los cuales pueden se obtenidos de diversas fuentes, como grabaciones de voz, registros escritos o interacciones en redes sociales (Gómez, 2019). Estos corpus representan colecciones extensas de enunciados gramaticales, que incluyen elementos léxicos (términos, frases), sintácticos (reglas gramaticales) y fonológicos (fonemas), utilizados para entrenar algoritmos de clasificación automática del lenguaje. Entre los modelos tradicionales más influyentes se encuentran los basados en n-grams, modelos ocultos de Markov (Hidden Markov Models, HMMs) y métodos de clasificación estadística, como Naive Bayes.

Modelo de N-gramass

Los modelos de lenguaje basados en N-gramass representan uno de los enfoques probabilísticos más clásicos en el PLN. Un N-gramas se define como una secuencia de n palabras consecutivas dentro de un texto. Por ejemplo, un bigrama es una secuencia de dos palabras como "agua caliente", mientras que un trigrama es una secuencia de tres, como "el agua caliente" (Jurafsky & Martin, 2025). Más allá de su definición estructural, el término “N-gramas” también se emplea para describir modelos probabilísticos que estiman la probabilidad de aparición de una palabra en función de las palabras anteriores en la secuencia. Estos modelos permiten asignar probabilidades a frases o textos completos, basándose en la frecuencia con la que ocurren ciertas combinaciones de palabras en grandes corpus lingüísticos.

Aunque los modelos de N-gramass han sido superados en rendimiento por arquitecturas más recientes como los Transformers, siguen siendo fundamentales para comprender los principios básicos del modelado lingüístico, incluyendo conceptos como la perplejidad, la división de conjuntos de entrenamiento y prueba, y estrategias como el muestreo y la

interpolación (es un método para "rellenar" datos faltantes o para predecir valores desconocidos dentro de un conjunto de datos). Su estructura sencilla los hace útiles como punto de partida tanto para la enseñanza como para el desarrollo inicial de herramientas lingüísticas (Jurafsky & Martin, 2025).

Modelos Ocultos de Markov

Los Modelos Ocultos de Markov (HMM, por sus siglas en inglés) son un tipo de modelo usado para trabajar con datos que ocurren en secuencia, como las palabras que se dicen al hablar. Lo que hacen estos modelos es tratar de adivinar qué pasa "detrás" de lo que vemos o escuchamos. Por ejemplo, aunque no veamos directamente si una palabra es un sustantivo o un verbo, el modelo puede hacer suposiciones basadas en las palabras que vienen antes o después; también podemos encontrar a los que llaman “ocultos” donde el sistema intenta descubrir lo que no se puede ver directamente, usando lo que sí se puede observar. Es como tratar de entender cómo funciona una máquina viendo solo lo que sale de ella. Este tipo de modelos ha sido muy útil en el procesamiento del lenguaje natural, en tareas como reconocer palabras habladas o clasificar las palabras según su tipo en una oración.

A diferencia de otros modelos más simples como los N-gramas, que solo se fijan en combinaciones de palabras que aparecen juntas, los HMMs miran también cómo puede cambiar el “estado” de una palabra a otra. Por ejemplo, si una palabra anterior fue un artículo como “el” o “la”, es muy probable que la siguiente palabra sea un sustantivo, y no un verbo (Molina Marco, 2004).

2.1.2 Modelos de Aprendizaje Profundo

El Aprendizaje Profundo (Deep Learning) es una subárea del aprendizaje automático que se basa en el uso de redes neuronales artificiales con múltiples capas de procesamiento. Estas capas permiten a los modelos aprender representaciones jerárquicas y abstractas de los datos, transformándolos progresivamente desde características simples hasta conceptos complejos. A diferencia de los enfoques tradicionales que requieren una ingeniería manual de características, el aprendizaje profundo extrae automáticamente las representaciones más relevantes a partir de grandes volúmenes de datos (LeCun, Bengio, & Hinton, 2015).

Este paradigma computacional ha sido considerado por muchos investigadores como una pieza clave de la cuarta revolución industrial, ya que su funcionamiento se inspira en la estructura y dinámica del cerebro humano. Las redes profundas realizan operaciones distribuidas a través de múltiples capas no lineales, lo que les permite discriminar y clasificar información compleja (Badillo et al., 2021).

Gracias a su capacidad para aprender automáticamente y generalizar eficientemente, los modelos de aprendizaje profundo han demostrado un rendimiento sobresaliente en tareas como el PLN, la visión por computadora, el reconocimiento de voz, la traducción automática y la generación de texto. Entre los modelos más representativos se encuentran las redes neuronales artificiales (ANN), las redes neuronales convolucionales (CNN) , y las redes recurrentes (RNN), cada uno adaptado a tipos específicos de datos y contextos de aplicación.

Redes Neuronales Artificiales (ANN)

Las Redes Neuronales Artificiales (ANN, por sus siglas en inglés) son modelos computacionales que imitan, de forma simplificada, el funcionamiento del cerebro humano. Se inspiran en la estructura de las redes neuronales biológicas y están formadas por unidades

llamadas neuronas artificiales, las cuales se organizan en capas y se conectan entre sí mediante enlaces ponderados. Cada neurona recibe señales, las procesa mediante una función matemática y transmite un resultado a otras neuronas, permitiendo el flujo de información dentro del sistema (Salas, 2004).

Estas redes tienen la capacidad de aprender a partir de los datos, es decir, ajustan automáticamente sus parámetros internos para adaptarse a patrones presentes en la información que reciben. No requieren que se les dé explícitamente una fórmula o modelo del problema: en cambio, extraen relaciones a partir de la experiencia, lo que las hace útiles para problemas donde hay muchos datos, pero pocas reglas conocidas (Salas, 2004)

Redes Recurrentes (RNN)

Las Redes Neuronales Recurrentes (RNN por sus siglas en inglés) se caracterizan por retener información, ya que tienen memoria para recordar lo que acabamos de decirles. Estas redes son perfectas para trabajar con frases que llevan secuencia, por ejemplo, cuando se escribe un mensaje (Pérez Guerrero, 2020). La forma de trabajar de esta red es que usa los mismos parámetros para entender todas las partes de una frase, evitando confusiones en nuevas frases.

Como menciona Graves (2014), estas redes no solo se fijan en lo último que escucharon, sino también en lo que ya tenían en mente. Por eso se usan en muchos ámbitos: desde la traducción, hasta identificar patrones de emociones en redes sociales. Básicamente, son como un puente entre nuestra manera de platicar y las máquinas

Redes Neuronales Convolucionales (CNN)

Las Redes Neuronales Convolucionales (CNN, por sus siglas en inglés) son un tipo de arquitectura dentro del aprendizaje profundo diseñada específicamente para el procesamiento de datos estructurados en forma de grillas (como las imágenes, que están compuestas por píxeles dispuestos en filas y columnas). Inspiradas en el funcionamiento de la corteza visual primaria del cerebro humano, estas redes buscan identificar patrones jerárquicos como bordes, texturas o formas mediante filtros que se aplican a través de la operación de convolución (Badillo et al., 2021). Su estructura típica incluye capas convolucionales, capas de reducción de las imágenes y capas completamente conectadas, donde las primeras se encargan de la extracción de características y las últimas de la clasificación.

Las CNN no solo permiten reconocer objetos en imágenes, sino también manejar variaciones espaciales, ya que los patrones aprendidos en una zona de la imagen pueden ser reconocidos en otras zonas sin necesidad de reaprendizaje. Además, presentan una capacidad para construir jerarquías de patrones: desde características simples como líneas, hasta composiciones complejas como formas completas de objetos (Badillo et al., 2021).

Diversas arquitecturas de CNN han sido desarrolladas dependiendo del tipo de datos que reciben y del tipo de resultados que generan. Por ejemplo, algunas redes están diseñadas para procesar imágenes como entrada y también generar imágenes como salida, lo cual es útil en tareas como la segmentación de objetos dentro de una imagen (es decir, distinguir qué parte es cielo, persona, suelo, etc.). Un tipo de estas redes es el modelo encoder-decoder, que transforma una imagen original en una nueva imagen que resalta ciertas zonas. Por otro lado, existen redes más profundas como las llamadas redes residuales, que fueron diseñadas para resolver el problema de que, al tener muchas capas, algunas redes no aprendían correctamente. Estas redes

incluyen caminos alternativos para que la información fluya mejor y así mejorar los resultados del aprendizaje (Carreón Díaz de León, 2023).

En este trabajo, las CNN se emplean para clasificar espectrogramas generados a partir de audios en maya y español con contenido médico y de otra naturaleza. Se experimenta con modelos como MobileNetV2, MobilNet3 y EfficientNetB0, entrenados en *Python* usando el entorno *notebook* de la plataforma *Google Colab*, a fin de evaluar su desempeño en tareas de clasificación con corpus limitados.

2.1.3 Modelos Transformers

Los modelos Transformers revolucionaron el campo de la inteligencia artificial, especialmente en el PLN. Fueron introducidos por Vaswani y su equipo en 2017 con una propuesta innovadora: dejar atrás el procesamiento lento y secuencial de las redes anteriores para usar en su lugar el mecanismo de *atención*. Este mecanismo permite que el modelo analice todas las palabras de una oración al mismo tiempo, entendiendo mejor su contexto y relaciones, como cuando leemos una frase completa para captar su significado global (González & Centenera, 2020). Gracias a esto, los Transformers son más rápidos y eficientes para tareas como traducción o comprensión de texto.

La verdadera fuerza de esta arquitectura se ve en modelos como *GPT*, que pueden generar texto, responder preguntas o resumir contenido sin necesidad de ser reentrenados para cada tarea nueva. Otros modelos basados en esta misma tecnología, como *BERT* o *T5,* han mejorado aún más la capacidad de las máquinas para entender y producir lenguaje casi como lo hacemos las personas. Hoy, los Transformers no solo se usan para texto; también están presentes

en áreas como la visión por computadora, demostrando ser pilares fundamentales de la inteligencia artificial actual.

2.1.4 Modelos usados en el maya

En los últimos años, el avance del PLN ha comenzado a extenderse hacia lenguas originarias, especialmente aquellas que han sido históricamente marginadas de los desarrollos tecnológicos. La lengua aya, en sus diversas variantes, ha sido objeto de recientes esfuerzos investigativos que buscan integrar estas lenguas a modelos computacionales mediante la creación de corpus, analizadores morfológicos, sistemas de etiquetado gramatical y traducción automática neuronal. A continuación, se presenta un resumen de investigaciones destacadas que han aplicado modelos de PLN en diferentes variantes de la lengua Maya. Esta revisión permite identificar tanto las estrategias metodológicas empleadas como las particularidades lingüísticas abordadas, lo que constituye un referente fundamental para la propuesta de este proyecto, centrado en el desarrollo de recursos especializados en el ámbito médico.

Tabla 1

Modelos de PLN en lenguas indígenas

Nombre del trabajo	Recurso (año)	Tipo de modelo	¿Qué es ese modelo?	Lengua Maya	Resumen
"Building Neural Machine Translation Systems for Indigenous Languages: The Case of Spanish–Mayan"	Rangel & Kobayashi (2024)	Traducción automática neuronal (NMT)	Modelo que aprende a traducir entre idiomas usando redes neuronales profundas con corpus paralelo.	Maya Yucateco, Chol	Entrenan modelos NMT para Español–Mayan usando corpus compilados desde fuentes como Wikipedia y Bibliotecas Digitales. Publican código y conjuntos de datos.
"Curated datasets and neural models for machine translation of informal registers between Mayan and Spanish vernaculars."	Lou et al. (2024)	NMT multirregistro	Similar a NMT, pero enfocado en traducción en contextos reales, distinguiendo entre lenguaje formal e informal.	Yucateco, K'iche', Q'eqchi', Chol, Mam, entre otros	Crean el corpus *MayanV* con versiones formales e informales de textos Mayas. Evalúan modelos de traducción entrenados con estos datos.

Nombre del trabajo	Recurso (año)	Tipo de modelo	¿Qué es ese modelo?	Lengua Maya	Resumen
"Part-of-Speech Tagging for K'iche' Maya"	Tyers & Howell (2021)	Etiquetado gramatical (POS tagging)	Asigna categorías gramaticales (como verbo o sustantivo) a cada palabra en una oración.	K'iche'	Comparan distintos métodos (CRF, RNN) para etiquetado POS. Prueban transfer learning de Español a K'iche'. Logran alto rendimiento con poco entrenamiento.
"An Open Morphological Analyzer for K'iche'"	Richardson & Tyers (2021)	Analizador morfológico	Descompone palabras en raíces y afijos; útil para comprensión lingüística profunda.	K'iche'	Desarrollan un analizador con más del 90% de cobertura en textos. Su herramienta es de código abierto y está alineada con estándares lingüísticos.

Fuente: Creación propia.

Estos trabajos permiten observar una evolución constante en el uso de modelos computacionales aplicados a variantes de la lengua maya, destacando un interés creciente por su inclusión en contextos digitales y tecnológicos. No obstante, persisten desafíos importantes, como la escasez de datos anotados, la variación dialectal y la necesidad de enfoques adaptados cultural y lingüísticamente. En este sentido, los avances revisados no solo sientan un precedente técnico, sino que también visibilizan la importancia de desarrollar herramientas lingüísticas que respeten la diversidad y funcionalidad comunicativa de las lenguas originarias. Este panorama justifica y fortalece la pertinencia de proyectos orientados al desarrollo de modelos PLN con enfoque específico, como el ámbito médico, donde la comprensión precisa del lenguaje puede contribuir a mejorar la atención multilingüe y el acceso equitativo a servicios de salud para comunidades Maya hablantes.

2.1.5 Modelos de PLN y aprendizaje profundo en el área médica

El uso del PLN en textos médicos ha demostrado ser crucial para estructurar y extraer información relevante a partir de datos clínicos no estructurados. Tareas como la tokenización (proceso mediante el cual un texto se divide en unidades lingüísticas mínimas llamadas tokens, como palabras o signos de puntuación), el reconocimiento de entidades nombradas (NER, por sus siglas en inglés, que consiste en identificar y clasificar nombres propios en categorías como personas, organizaciones o lugares), el etiquetado gramatical (asignación de categorías gramaticales como sustantivo, verbo o adjetivo a cada palabra de un texto, también conocido como análisis morfosintáctico) y la recuperación de información (RI, entendida como el proceso de localizar y extraer datos relevantes de grandes volúmenes de información textual) son fundamentales en el desarrollo de sistemas de PLN, ya que permiten estructurar, entender y manipular el lenguaje humano de forma computacional. No obstante, a diferencia del

reconocimiento de entidades comunes como los nombres propios, fechas o ubicaciones, las entidades médicas aún presentan un rendimiento significativamente menor debido al gran número de terminologías, la constante aparición de nuevos conceptos, y la alta ambigüedad de la nomenclatura clínica (Quevedo-Marcos, 2020).

Estas limitaciones se evidencian, por ejemplo, cuando un sistema es capaz de identificar el nombre de un medicamento, pero falla al extraer con precisión su posología (dosis y frecuencia con la que debe administrarse un medicamento) o vía de administración. La existencia de múltiples formas de escribir o abreviar un mismo término, como “HCT”, “Hidrocortisona” o “Hidcortisona”, puede provocar que un modelo interprete estos términos como “diferentes”, lo que aumenta la cantidad de vocabulario necesario (Reinoso González & Zhirzhan Cabrera, 2022). Para mitigar estos problemas, se han desarrollado variantes especializadas de modelos de PLN como BioBERT (Lee et al., 2020) y ClinicalBERT, entrenados sobre corpus médicos con el fin de mejorar el reconocimiento de entidades y relaciones en contextos clínicos (Alsentzer et al., 2019;).

En paralelo, la integración de la inteligencia artificial (IA) en el laboratorio clínico ha transformado el análisis de datos médicos, favoreciendo diagnósticos más ágiles y una gestión más precisa de la información.

Asimismo, los agentes conversacionales han emergido como herramientas complementarias en la atención médica, especialmente en entornos privados o urbanos. Su implementación a través de plataformas de mensajería como WhatsApp o Facebook permite resolver consultas básicas de manera automatizada, optimizando la experiencia del paciente (Guanoluisa, Chicaiza & Avalos, 2021). Para alcanzar su funcionalidad plena, estos agentes

deben estar diseñados con modelos de PLN robustos y configurados según las características culturales y lingüísticas del público al que se dirigen.

En este contexto, los retos técnicos y éticos del uso de PLN en el ámbito médico se vuelven más sensibles cuando se trata de comunidades indígenas. La falta de recursos lingüísticos digitales, como corpus paralelos en lenguas originarias, dificulta el desarrollo de herramientas tecnológicas que realmente comprendan y respeten la forma de expresarse de estos pueblos. Por eso, es urgente crear materiales que ayuden a resolver el problema y que no solo mejoren la comunicación entre pacientes y personal de salud, sino que también contribuyan a cerrar la brecha tecnológica y a garantizar que el derecho a la salud sea una realidad para todos, sin importar la lengua que hablen.

2.1.6 Lenguas indígenas

México es reconocido como uno de los países con mayor diversidad lingüística en el mundo, al contar oficialmente con 69 lenguas nacionales: 68 de origen indígena y el español como lengua de uso mayoritario. El gran número de lenguas en el país refleja la riqueza cultural que se derivada de los pueblos originarios que habitaban el territorio y que han preservado, adaptado y transmitido sus lenguas a lo largo del tiempo. De acuerdo con el Instituto Nacional de Lenguas Indígenas (INALI, 2009), se considera lengua indígena a toda aquella que provenga de los pueblos originarios asentados históricamente en México.

Las lenguas indígenas mexicanas no solo son sistemas de comunicación complejos y estructurados, sino también vehículos de transmisión de saberes, prácticas culturales y cosmovisiones. Estas lenguas presentan gramáticas completas, estructuras orales consolidadas y funciones sociales activas, muchas de ellas sin tradición escrita, pero con una enorme riqueza en

el plano simbólico y funcional (Ramos Ramírez & Islas Flores, 2019). Desde el punto de vista sociolingüístico, estas lenguas se distribuyen en al menos 11 familias lingüísticas, con numerosas variantes dialectales que reflejan la diversidad geográfica y cultural del país. El Catálogo de las Lenguas Indígenas Nacionales reconoce, dentro de estas 68 lenguas, un total de 364 variantes lingüísticas diferenciadas, basadas en criterios de inteligibilidad mutua y uso comunitario (INALI, 2009), lo que refleja uno de los principales problemas, la cantidad de material de las lenguas para su uso en nuevas tecnologías son limitadas. Según datos del Censo de Población y Vivienda 2020, en México existen aproximadamente 7.36 millones de personas hablantes de alguna lengua indígena, lo que representa cerca del 6.1% de la población total del país (INEGI, 2020). Hablando geográficamente, los hablantes de lenguas indígenas se concentran principalmente en los estados del sur y sureste del país, como Oaxaca, Chiapas, Veracruz, Yucatán y Quintana Roo. En estas regiones no solo se conserva un número importante de hablantes, sino también una notable diversidad de variantes. La lengua Maya, por ejemplo, es una de las más habladas, con alrededor de 800,000 hablantes del Maya yucateco registrados principalmente en la península de Yucatán (INEGI, 2020). Esta lengua forma parte de la familia Maya, que incluye más de 30 lenguas vivas distribuidas en países de Mesoamérica, y que constituye una de las tradiciones lingüísticas más documentadas y resilientes del continente (Bricker, 1999).

En el contexto actual, la lengua maya ha encontrado nuevas formas de expresión y revitalización a través del uso de redes sociales, plataformas digitales y espacios de educación formal. Jóvenes hablantes, creadores de contenido y activistas lingüísticos emplean medios como TikTok, Facebook o YouTube para compartir adivinanzas, tutoriales, memes, relatos

tradicionales y mensajes cotidianos en Maya, generando así una presencia constante en los entornos digitales actualmente. Este fenómeno no solo contribuye a la visibilización y normalización del idioma, sino que también fortalece el orgullo identitario y promueve su transmisión entre generaciones. Además, el acceso a cursos de lengua Maya en universidades, centros culturales y espacios comunitarios ha crecido, generando una comunidad activa de estudiantes y hablantes comprometidos con su preservación.

Estos cambios han despertado un interés por crear corpus lingüísticos que usen tanto el habla formal como el habla espontáneo del Maya, así como la creación de modelos computacionales capaces de procesar esta lengua en contextos reales. En este sentido, el presente estudio propone aplicar modelos de PLN, en específico las CNN al ámbito médico, facilitando la comunicación entre paciente y personal de salud mediante el uso del maya y el español. Esta línea de trabajo busca no solo mejorar la atención médica bilingüe, sino fortalecer el uso del maya en contextos clave para el bienestar de las comunidades.

2.2. DEFINICIÓN DE TÉRMINOS BÁSICOS

2.2.1 Lenguaje Natural

El Lenguaje Natural es el sistema de comunicación que utilizamos las personas de manera cotidiana. Surge de forma espontánea en las comunidades humanas y se aprende naturalmente durante la infancia a través de la interacción social, sin necesidad de instrucción formal (Labadie, 2001). A diferencia de los lenguajes artificiales, el lenguaje natural es flexible, creativo y está lleno de expresiones. Incluye no solo palabras, sino también gestos, y tono de voz que enriquecen su significado.

2.2.2 Procesamiento de Lenguaje Natural

El Procesamiento de Lenguaje Natural (PLN) es una rama de la inteligencia artificial que busca que las máquinas comprendan, interpreten y generen lenguaje humano de forma automatizada. A diferencia de herramientas que solo procesan texto o sonido de manera superficial, el PLN intenta captar el significado, la intención y el contexto detrás de las palabras, haciendo posible una comunicación más natural entre personas y sistemas computacionales (Gelbukh, 2010).

Desde un punto de vista técnico, el PLN trabaja en varios niveles: desde el análisis de palabras sueltas (nivel léxico) y la estructura de las oraciones (nivel sintáctico), hasta la interpretación del significado (nivel semántico) y la adaptación al contexto situacional (nivel pragmático) (Manrique-Losada, 2015).

Gracias a los avances recientes en modelos de redes neuronales como los *Transformers*, el PLN hoy permite desarrollar asistentes virtuales, traductores automáticos y sistemas de búsqueda inteligente con capacidades cada vez más humanas. En el presente trabajo el PLN se convierte en una herramienta clave para reducir brechas tecnológicas, garantizar el acceso a servicios básicos como la salud y promover la inclusión digital desde un enfoque intercultural.

2.2.3 Corpus

En el ámbito del PLN y la lingüística computacional, un corpus es una colección de textos (ya sean orales o escritos) reunidos con el fin de ser analizados. Estos textos sirven como base para estudiar el uso real del lenguaje, así como para entrenar y evaluar modelos computacionales de análisis lingüístico (Evert, 2015). Los corpus pueden ser monolingües, bilingües o multilingües, en este caso maya y español. Su elaboración implica criterios de

selección, separación y traducción, lo cual garantiza que reflejen con fidelidad las características de una lengua o variedad determinada (McEnery & Hardie, 2012).

En contextos de aprendizaje automático y PLN, los corpus son esenciales para el desarrollo de tareas como el etiquetado gramatical (*POS tagging*), el reconocimiento de entidades nombradas (NER), el análisis sintáctico y la traducción automática. Además, en el caso de lenguas indígenas, la construcción de un corpus de maya - español representa no solo una tarea técnica, sino también una acción vital para la preservación y revitalización del conocimiento lingüístico (Maxwell & Hughes, 2006). Para fines de esta investigación se usará un corpus bilingüe, de maya y español, las dos lenguas que más se usan en la zona.

2.2.4 Acústica

La acústica es la rama de la física que estudia el sonido: cómo se origina, cómo viaja a través de diferentes medios como el aire o el agua, y cómo lo percibimos los seres humanos. Su estudio no solo es para fines científicos, ya que la acústica es parte de la vida cotidiana, desde cómo escuchamos música hasta cómo funciona un audífono o cómo se diseñan los espacios para que el sonido sea claro, como ocurre en teatros o salas de clase.

En términos simples, el sonido es una vibración que se transmite a través de un medio físico. Cuando algo vibra, como las cuerdas de una guitarra o nuestras cuerdas vocales al hablar, estas vibraciones generan ondas que viajan por el aire y llegan a nuestros oídos. Allí, el oído transforma esas ondas en señales eléctricas que el cerebro interpreta como sonidos (Merino de la Fuente & Muñoz-Repiso, 2013).

Además, la acústica es fundamental en el diseño de tecnologías modernas como micrófonos, altavoces o asistentes virtuales, y también en la creación de modelos

computacionales que permiten a las máquinas interpretar la voz humana, lo cual es clave para aplicaciones como el reconocimiento de voz o la traducción automática. Para fines de esta investigación, la acústica se considera como el punto de partida para generar representaciones visuales del sonido en forma de espectrogramas, a partir de audios en maya y español. Estos espectrogramas permiten analizar patrones acústicos mediante CNN , sin estudiar directamente el fenómeno físico del sonido, sino su aplicación en modelos computacionales para clasificación automática en el contexto médico.

2.2.5 Pratt

Praat es una herramienta computacional de libre acceso que tiene un uso amplio en el análisis del habla y otros aspectos acústicos del lenguaje, ya que permite examinar detalles del sonido, como la frecuencia, la duración, la intensidad y el timbre cono representaciones visuales que se llaman espectrogramas que ayudan a observa de una manera visual su comportamiento. (Boersma & Weenink, 2023).

Praat permite analizar las grabaciones de voz con gran precisión, por lo que se vuelve útil al investigar cómo se producen los sonidos del habla, en este caso las diferencias del idioma del maya y español. Esta herramienta se ha convertido en un estándar dentro de la fonética acústica y es empleada en estudios sobre lenguas originarias, adquisición del lenguaje, fonología comparada e incluso en el desarrollo de tecnologías de reconocimiento de voz (Ladefoged & Johnson, 2014).

En el contexto del presente trabajo, Praat será empleado para analizar audios grabados en lengua Maya, con el fin de extraer características acústicas que se encontrarán reflejadas en los

espectrogramas que permitirán identificar las variaciones en la pronunciación que servirán de base para el diseño de corpus y recursos lingüísticos útiles en sistemas de PLN.

UNIDAD III. MÉTODO

3.1 RECOLECCIÓN Y PREPARACIÓN DE DATOS

3.1.1 Fuentes de datos

Se inició con el corpus Maasab, un conjunto de carpetas con archivos de audio en maya y español que, en teoría, debían formar pares de traducción correspondientes. Se contaba con aproximadamente 3000 audios. Sin embargo, durante la revisión inicial se identificó que no todos los audios tenían su traducción al español y viceversa, siendo una anomalía significativa en la organización de los archivos.

Separación: Durante la organización del corpus, se identificó que existían audios adicionales, lo que resultó en inconsistencias entre las grabaciones en maya y sus respectivas traducciones al español. Este exceso de registros, que repetían las mismas frases en múltiples ocasiones, complicó significativamente el proceso de alineación y clasificación. La situación ocasiono un pequeño retraso, ya que el proyecto partía del supuesto de que los audios estarían correctamente emparejados y ordenados para facilitar su procesamiento computacional**.**

Para organizar los audios del corpus, se crearon carpetas donde se enviaron los audios según el idioma siendo una denominada "Maya" y otra "Español". El proceso consistió en revisar audio por audio y distribuirlos manualmente en estas carpetas según el idioma correspondiente, dando así inicio a la fase de separación del corpus.

Alineación: El siguiente paso consistió en la creación de plantillas de Excel para cada carpeta principal, con columnas predefinidas: *género*, *nombre*, *audio YUA (Maya)* y *audio ES (Español)*. Para agilizar la alineación de los audios previamente separados en dos carpetas, se desarrollaron *scripts* de Python que se ejecutaron en *Visual Studio Code*, lo que permitió evitar errores y acelerar el proceso. Al ejecutar el script, se generaban automáticamente los documentos de Excel, pero requerían una verificación manual para asegurar que los audios estuvieran en las carpetas correctas en caso de sospechar algún error entre los pares de audio. Los audios no alineados inicialmente se movían al final de la lista para una segunda revisión, donde se determinaba si existía su traducción correspondiente o si debían eliminarse. Los metadatos (*género* y *nombre*) se insertaron manualmente, ya que el objetivo principal del script era estructurar el documento base y alinear los archivos de audio, asignando solo los audios en sus respectivas carpetas.

Análisis: La siguiente fase consistió en utilizar Praat[2], una herramienta especializada en lingüística y fonética para el análisis, síntesis y manipulación del habla. Se recibió un taller introductorio sobre el funcionamiento del software y sus aplicaciones para el proyecto. Después, exploramos de manera independiente las funcionalidades del programa, enfocándonos en la generación de espectrogramas y la elaboración de *scripts* básicos para automatizar procesos. El aprendizaje autodidacta nos permitió conocer más a detalle las herramientas y poder usar las necesarias para el procesamiento y visualización de los datos de audio.

Aumento del dataset:

[2] https://www.fon.hum.uva.nl/praat/download_win.html

Además del corpus Maasab, se decidió utilizar otros corpus de libre acceso y que fueron utilizados en un trabajo previo, ya que se alineaba a lo que buscábamos y nos ayudaba con la cantidad de datos necesarios para el entrenamiento de los modelos de CNN (Buenfil Aguilar, Fernández-Sabido, Reyes-Magaña, Basto-Díaz, Curi-Quintal, & Sánchez Siordia, 2025).

3.1.2 Características del *dataset*

En la siguiente tabla se muestra los corpus previamente usados por Buenfil Aguilar et al (2025) para el entrenamiento de tres arquitecturas.

Tabla 2

Corpus usados para el entramiento de modelos CNN

Idioma	Origen	Tema	Cantidad de muestras
Audios Maya	Maasab[3]	Frases médico paciente	785
	DoReCo[4]	Conversaciones naturales	792
	T'áansil[5]	Conversaciones naturales	127
	Ciempiés[6]	Prensa, literatura y conversaciones	0
Audios Español	Maasab	Frases médico paciente	795
	DoReCo	Conversaciones naturales	0
	T'áantsil	Conversaciones naturales	0
	Ciempiés	Prensa, literatura y conversaciones	1318

[3] https://sites.google.com/view/maasabmakachi/inicio?authuser=1

[4] https://doi.org/10.34847/nkl.7cbfq779

[5] https://taantsil.com.mx

[6] LREC. vol. 14, pp. 371–375 (2014)

Fuente: Buenfil Aguilar, Fernández-Sabido, Reyes-Magaña, Basto-Díaz, Curi-Quintal, & Sánchez Siordia, 2025

Comentado [SF1]: Quitar la palabra "Nota" de las tablas, con "Fuente" es suficiente

3.2 GENERACIÓN DE ESPECTROGRAMAS

3.2.1 Representación de audio como imágenes

Utilizando el programa Praat, se crearon espectrogramas para todos los audios en maya y español. Estos espectrogramas se guardaron en nuevas carpetas dentro del mismo proyecto, manteniendo el mismo orden que los audios originales. Estas imágenes son el material que se usó para entrenar el modelo de inteligencia artificial en la siguiente etapa.

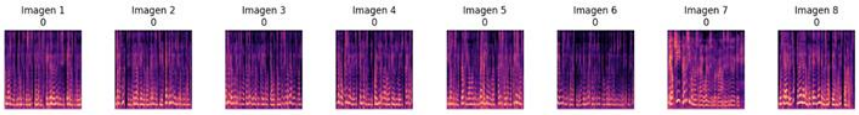
El programa Praat crea espectrogramas dividiendo el audio en segmentos cortos. A cada segmento le aplica un análisis matemático (Transformada de *Fourier*) que convierte el sonido en información visual. Esto permite ver cómo cambian las frecuencias y la intensidad del sonido a lo largo del tiempo, creando una imagen (espectrograma) que representa visualmente el audio.

El resultado es una imagen llamada espectrograma, que muestra cómo va cambiando el sonido a lo largo del tiempo. En el eje horizontal se representa el tiempo y en el vertical las frecuencias. La intensidad del sonido se muestra mediante colores o tonos de gris: entre más fuerte sea un sonido en cierta frecuencia, más se notará en la imagen. Así, el espectrograma nos permite "ver" el sonido de manera clara y detallada.

Ejemplos de los espectrogramas en maya:

Figura 1

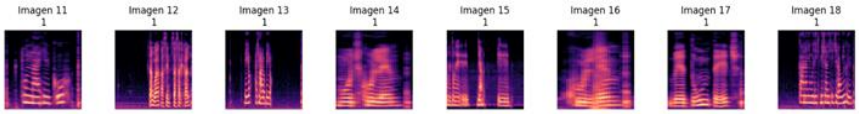
Ejemplo de los espectrogramas en español



Fuente: Creación propia

Figura 2

Ejemplos de los espectrogramas en Maya



Fuente: Creación propia

3.3 ARQUITECTURA DE LA RED NEURONAL CONVOLUCIONAL

3.3.1 Red neuronal convolucional

Para este proyecto, se optó por utilizar la arquitectura de CNN. Este tipo de modelo es ideal para el procesamiento de imágenes, ya que está específicamente diseñado para reconocer patrones de forma eficiente y jerárquica.

3.2. TRANSFERENCIA DE CONOCIMIENTO

Esta técnica utiliza una red neuronal pre-entrenada en conjuntos de datos masivos (ej: ImageNet[7]) como punto de partida para clasificar espectrogramas. Estas redes pre-entrenadas ya han aprendido a reconocer características visuales genéricas, lo que acelera y mejora el rendimiento en nuevas tareas.

[7] https://www.image-net.org/

3.3. PROCESO IMPLEMENTADO

3.3.1. Modelos elegidos

Para este trabajo se seleccionaron modelos ligeros de CNN , diseñados específicamente para funcionar en equipos con capacidad limitada de memoria y hardware. La elección de modelos responde a la necesidad de tener recursos computacionales reducidos.

Los modelos elegidos para su entrenamiento y evaluación fueron: MobileNetV2, MobileNetV3 y EfficientNetB0. Estas arquitecturas destacan por su equilibrio entre eficiencia computacional y capacidad de reconocimiento de patrones visuales, lo que las hace ideales para procesar espectrogramas. Su adaptabilidad a dispositivos de bajos recursos los convierte en opciones técnicas viables para los objetivos planteados en esta investigación.

Transferencia:

- Se congelaron las capas iniciales (que detectan características básicas).
- Se reentrenaron las capas finales para adaptarlas a la clasificación de espectrogramas.
- Nueva tarea: El modelo se especializó en reconocer patrones acústicos en espectrogramas de audios en maya y español.

Ejemplo de código:

Figura 3

Ejemplo de un modelo pre-entrenado

```
# Freeze the base model
base_model.trainable = False

# Preprocess the data
x_train_norm = preprocess_input(x_train)
x_val_norm = preprocess_input(x_val)
x_test_norm = preprocess_input(x_test)

# Extract features using the base model
x_train_features = base_model.predict(x_train_norm)
x_val_features = base_model.predict(x_val_norm)
x_test_features = base_model.predict(x_test_norm)

print(f"Shape of train features: {x_train_features.shape}")
print(f"Shape of val features: {x_val_features.shape}")
print(f"Shape of test features: {x_test_features.shape}")
```

3.3.2 Diseño de la arquitectura

Sobre la base del modelo pre-entrenado, se implementaron 5 capas personalizadas con las siguientes características:

- **Capa de aplanamiento:** Transforma la salida multidimensional de la extracción de características en un vector unidimensional, permitiendo la conexión con capas densas.
- **Capa densa (256 neuronas):** Totalmente conectada con función de activación ReLU y regularización L2 (λ=0.01) para penalizar pesos grandes y reducir sobreajuste.
- **Capa de normalización por lotes:** Estabiliza el entrenamiento mediante la normalización de las activaciones de la capa anterior.

- **Capa de dropout (50%):** Desactiva aleatoriamente la mitad de las unidades durante el entrenamiento para mejorar la generalización del modelo.
- **Capa de salida:** Capa densa con 2 neuronas y activación sigmoide para clasificación binaria (Español vs. Maya).

Finalizada la arquitectura, se compiló el modelo definiendo el optimizador Adam, la función de pérdida *binary_crossentropy* (para clasificación binaria) y la métrica de precisión. Adicionalmente, se generó un resumen de la arquitectura con detalles de capas, formas de salida y cantidad de parámetros.

Ejemplo de código:

Figura 4

Código de las 5 capas adicionales



```
from keras.models import Sequential
from keras.layers import Flatten, Dense, Dropout, BatchNormalization
from keras.regularizers import l2
from keras.callbacks import EarlyStopping
from keras.optimizers import Adam
import tensorflow as tf # Import tensorflow to use data_augmentation

optimizer = Adam(learning_rate=parameters["learning_rate"]) # se encarga de actualizar los pesos del modelo durante el entrenamiento

# inicializa un modelo secuencial, las capas se añaden una tras otra en una pila lineal
model = Sequential()

# Add data augmentation layer
model.add(data_augmentation)

# CAPA 1
# capa de aplanamiento que toma la salida multidimensional de la extracción de características (del modelo base) y la aplana en una matriz unidimensional,
# preparándola para las capas completamente conectadas.
model.add(Flatten(input_shape=x_train_features.shape[1:]))

# CAPA 2
# capa densa (completamente conectada) con 256 neuronas y una función de activación ReLU,
# incluye regularización L2 para ayudar a prevenir el sobreajuste
# L2 añade una penalización a la función de pérdida basada en los valores al cuadrado de los pesos

#model.add(Dense(256, activation='relu', kernel_regularizer=l2(1e-4)))
model.add(Dense(256, activation='relu', kernel_regularizer=l2(1e-4)))

# CAPA 3
# capa de normalización por lotes para estabilizar el proceso de entrenamiento y mejorar el rendimiento al normalizar las entradas de la siguiente
model.add(BatchNormalization())

# CAPA 4
# capa de abandono, establece aleatoriamente una fracción de las unidades de entrada a 0 durante el entrenamiento. Esta es otra técnica para evitar el sobreajuste.
model.add(Dropout(0.7))

# CAPA 5
# capa densa de salida con 2 neuronas (dos clases de lenguas) y una función de activación sigmoidea
model.add(Dense(2, activation='sigmoid'))

# configura el modelo para el entrenamiento, especifica el optimizador, la función de pérdida (binary_crossentropy para la clasificación binaria) y la métrica a evaluar (precisión)
model.compile(optimizer=optimizer, loss='binary_crossentropy', metrics=['accuracy'])

# imprime un resumen de la arquitectura del modelo, incluyendo las capas, las formas de salida y el número de parámetros
model.summary()
```

3.3.3 Hiperparámetros

Se definieron los siguientes parámetros para el proceso de entrenamiento del modelo:

- **Tasa de aprendizaje (learning rate):** 1e-4 (0.0001), valor que determina la magnitud de ajuste de los pesos de la red en función del gradiente del error.
- **Tamaño de lote (batch size):** 20, correspondiente al número de muestras procesadas antes de actualizar los pesos del modelo.
- **Épocas (epochs):** 30, número de iteraciones completas sobre el conjunto de datos de entrenamiento.

Ejemplo:

Figura 5

Hiperparametros

```
[ ]  parameters = {"batch_size":20, "epochs":30, "learning_rate": 1e-4}
```

3.4 ENTRENAMIENTO DEL MODELO

3.4.1 División del *dataset*

La división de los datos se realizó en tres subconjuntos: entrenamiento, validación y prueba. Primero, se calcularon las proporciones de cada división según los porcentajes definidos en el diccionario split_usado.

En la primera etapa, se separó un conjunto de prueba independiente (*x_test, y_test)* del resto de los datos, utilizando el parámetro *test_size* para especificar el porcentaje asignado a

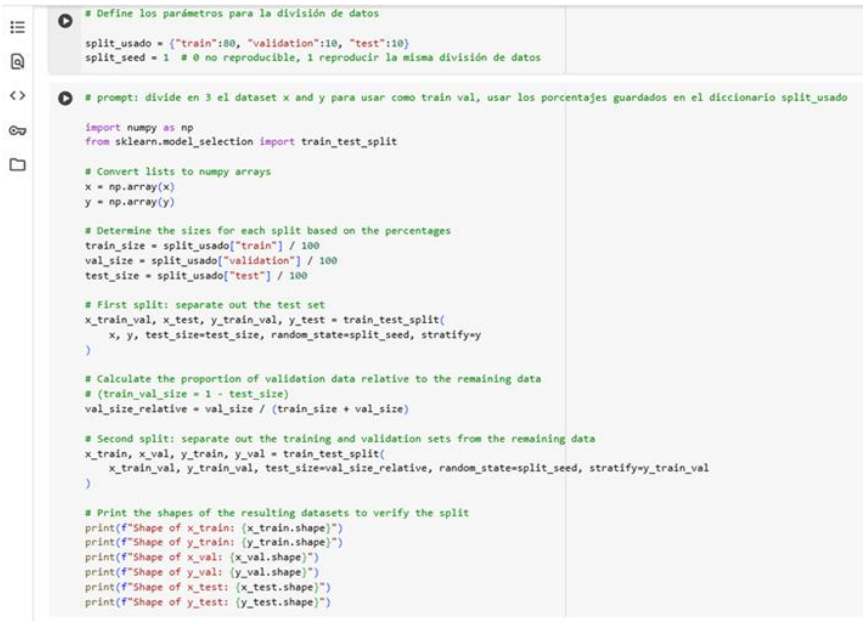
prueba. Los datos restantes formaron un conjunto temporal de entrenamiento-validación (*x_train_val, y_train_val*).

Posteriormente, se calculó la proporción relativa que correspondería al conjunto de validación respecto al conjunto temporal. En la segunda etapa, este conjunto temporal se dividió en los subconjuntos finales de entrenamiento (*x_train, y_train*) y validación (*x_val, y_val*). Para garantizar la reproducibilidad y mantener la distribución original de clases, se utilizaron los parámetros *test_size* (con el tamaño relativo calculado), *random_state y stratify*.

Finalmente, se verificó la correcta división imprimiendo las dimensiones de los *arrays* resultantes. Este proceso asegura que el modelo se entrene, ajuste y evalúe de manera adecuada y representativa.

Figura 6

Código de la división de DataSet



```
# Define los parámetros para la división de datos

split_usado = {"train":80, "validation":10, "test":10}
split_seed = 1  # 0 no reproducible, 1 reproducir la misma división de datos
```

```
# prompt: divide en 3 el dataset x and y para usar como train val, usar los porcentajes guardados en el diccionario split_usado

import numpy as np
from sklearn.model_selection import train_test_split

# Convert lists to numpy arrays
x = np.array(x)
y = np.array(y)

# Determine the sizes for each split based on the percentages
train_size = split_usado["train"] / 100
val_size = split_usado["validation"] / 100
test_size = split_usado["test"] / 100

# First split: separate out the test set
x_train_val, x_test, y_train_val, y_test = train_test_split(
    x, y, test_size=test_size, random_state=split_seed, stratify=y
)

# Calculate the proportion of validation data relative to the remaining data
# (train_val_size = 1 - test_size)
val_size_relative = val_size / (train_size + val_size)

# Second split: separate out the training and validation sets from the remaining data
x_train, x_val, y_train, y_val = train_test_split(
    x_train_val, y_train_val, test_size=val_size_relative, random_state=split_seed, stratify=y_train_val
)

# Print the shapes of the resulting datasets to verify the split
print(f"Shape of x_train: {x_train.shape}")
print(f"Shape of y_train: {y_train.shape}")
print(f"Shape of x_val: {x_val.shape}")
print(f"Shape of y_val: {y_val.shape}")
print(f"Shape of x_test: {x_test.shape}")
print(f"Shape of y_test: {y_test.shape}")
```

3.4.2 Entrenamiento

Función de pérdida

La función de pérdida mide el rendimiento del modelo al cuantificar el error entre las predicciones y los valores reales. Su elección depende del tipo de problema (ej: clasificación binaria) y las características de los datos.

Optimizador

El optimizador actualiza los pesos de la red para minimizar la función de pérdida. Su selección impacta directamente en la velocidad de convergencia, la estabilidad del entrenamiento y el rendimiento final del modelo.

Técnicas de regularización

Estas técnicas previenen el sobreajuste (*overfitting*) al mejorar la generalización del modelo. Entre las estrategias comunes se incluyen la regularización L2 y el *dropout*, que reducen la complejidad del modelo durante el entrenamiento.

Ejemplo de código:

```
optimizer = Adam(learning_rate=parameters["learning_rate"])
model.compile(optimizer=optimizer, loss='binary_crossentropy', metrics=['accuracy'])
```

3.4.3. Monitoreo del entrenamiento

Análisis de curvas de aprendizaje

Las gráficas de *train_accuracy* y *val_accuracy* permiten evaluar el rendimiento del modelo durante el entrenamiento:

- ***train_accuracy***: Precisión en los datos de entrenamiento.
- ***val_accuracy***: Precisión en datos de validación (no usados durante el entrenamiento).

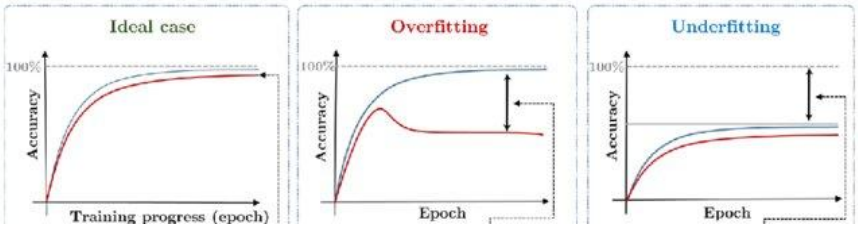
Interpretación:

La figura muestra de forma ilustrativa los casos que pueden presentarse[8].

[8] Imagen tomada de https://www.researchgate.net/publication/349898718_Essentials_of_AI_Techniques_With_a_focus_on_medicine_and_healthcare/figures?lo=1

Figura 7

Ejemplos de curvas de aprendizaje



Nota Referencia:

https://www.researchgate.net/publication/349898718_Essentials_of_AI_Techniques_With_a_focus_on_medicine_and_healthcare/figures?lo=1

- **Buen rendimiento**: Ambas curvas aumentan y convergen, manteniendo una brecha mínima entre ellas.
- **Sobreajuste (overfitting)**: Alta *train_accuracy* pero baja *val_accuracy*. El modelo memoriza el conjunto de entrenamiento, pero no generaliza. *Soluciones*: Aplicar técnicas de regularización (dropout, aumento de datos) o *early stopping*.
- **Subajuste (underfitting)**: Ambas curvas muestran valores bajos. El modelo no captura patrones suficientes. *Soluciones*: Incrementar la complejidad del modelo, ajustar hiper-parámetros o aumentar las épocas de entrenamiento.

Análisis mediante matriz de confusión

La matriz de confusión se utilizó para evaluar los aciertos y errores del modelo en la clasificación binaria (maya vs español). Esta técnica permite:

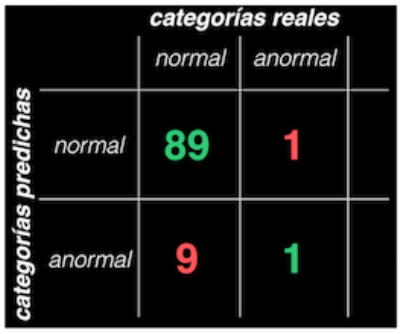
- Identificación de errores: Detectar confusiones entre clases (ej: predicciones incorrectas de "español" como "maya" o viceversa).
- Cálculo de métricas: Derivar indicadores de rendimiento como precisión, recall y F1-score a partir de los valores de la matriz.
- Visualización intuitiva: Representación gráfica con colores y anotaciones para facilitar la interpretación de los resultados.

Implementación:

Se ejecutaron las imágenes del conjunto de validación a través de la red neuronal y se generó la matriz comparando las etiquetas reales con las predicciones.

Figura 8

Ejemplo de una matriz de confusión



Fuente: Creación propia

3.5 EVALUACIÓN DEL MODELO

3.5.1 Métricas de evaluación

Para cuantificar el rendimiento del clasificador se calcularon las siguientes métricas:

- **Exactitud (Accuracy)**: Proporción de predicciones correctas sobre el total.

  print(f"Accuracy: {accuracy}")

- **Precisión (Precision)**: Porcentaje de verdaderos positivos entre todas las predicciones positivas.

  print(f"Precision: {precision}")

- **Sensibilidad (Recall)**: Capacidad del modelo para detectar correctamente los casos positivos reales.

  print(f"Recall: {recall}")

- **F1-Score**: Media armónica entre precisión y sensibilidad, útil para conjuntos desbalanceados.

  print(f"F1 Score: {f1}")

3.6 BITÁCORA DE EXPERIMENTOS

3.6.1. Herramientas

El proceso de control de experimentos se implementó mediante un sistema de registro que consta de tres etapas principales:

- **Creación de bitácora digital**:

  Se genera un archivo CSV estructurado para documentar todos los experimentos realizados.

- **Generación de identificadores únicos**:

  Se calcula un *hash* criptográfico utilizando los parámetros clave del experimento (hiperparámetros, conjunto de datos y configuración del modelo), creando así una firma digital única para cada configuración experimental.

Verificación y registro:

El sistema consulta la bitácora existente mediante el *hash* generado para detectar posibles repeticiones de experimentos. Posteriormente, registra los nuevos experimentos con todos sus metadatos relevantes. Esta implementación permite mantener un historial experimental organizado, evita la duplicación de esfuerzos y facilita la reproducibilidad de los resultados mediante el uso de identificadores únicos basados en la configuración exacta de cada experimento.

Figura 9

Fragmentos de código para registro de experimento

```
[ ] import pandas as pd
    try:
        df_log = pd.read_csv(f"{directorio_de_trabajo}/log.csv")
    except FileNotFoundError:
        df_log = pd.DataFrame(columns=["ID_Exp", # contador de experimentos
                                       "Hash", # identificador único generado usando todos los campos
                                       "Languages", # lenguas que se entrenan
                                       "Audio_Folders_Used", # carpeta de audios
                                      "Image_Amount", # cantidad de audios por cada lengua
                                       "hasSilence", # false si los silencios fueron removidos con audacity
                                       "Audio_Length", # longitud de los audios, empty string if wasn't standarized, use int seconds otherwise
                                       "Balance", # indicar si se balancea al número de audios de la clase minoritaria: 0 no, /1, si
                                       "Audios_usados", # si se balanceó, cuántos audios por lengua
                                       "Model", # modelo entrenado
                                       "Data_augmentation", # estrategias de aumento de datos
                                       "Parameters", # batch_size, epochs y learning_rate
                                       "Split_usado", # division de los datos
                                       "Split_Seed",
                                       "Results", #: Accuracy, Recall, Precision, F1
                                       "Notes" # observaciones especiales
                                       ])

    df_log.to_csv(f"{directorio_de_trabajo}/log.csv", index=False)
```

Figura 10

Código del hash (identificador único)



Figura 11

Código para registro de experimento en formato CSV

```python
import pandas as pd
df_log = pd.read_csv(f"{directorio_de_trabajo}/log.csv")

# Define the list of audio folders used
folder_path_list = [
    "spanish_no_silence",
    "mayan_without_silence"
]

# Calcula ID experimento
ID_Exp = f"EXP{len(df_log)}"


new_exp = {
    "ID_Exp": ID_Exp,
    "Hash": hash,
    "Languages": languages,
    "Audio_Folders_Used": folder_path_list,
    "Image_Amount": image_amount,
    "hasSilence": hasSilence,
    "Audio_Length": audio_length,
    "Balance": balance,
    "Audios_usados": numero_audios_usados, # si se balanceó, cuántos audios por lengua
    "Model": used_model,
    "Data_augmentation": data_augmentation_strategies,
    "Parameters": parameters,
    "Split_usado": split_usado, # division de los datos
    "Split_Seed": split_seed,
    "Results": f"Accuracy: {accuracy} Recall: {recall} Precision: {precision} F1: {f1}",
    "Notes": "tratando de reproducir los resultados del paper a partir de los espectogramas sin silencios"
}

df_log = pd.concat([df_log, pd.DataFrame([new_exp])], ignore_index=True)
df_log.to_csv(f"{directorio_de_trabajo}/log.csv",index=False)
```

En la fase final del proceso experimental, se implementó un protocolo de preservación de resultados que comprende dos acciones críticas:

- **Guardado del modelo entrenado**:

  El modelo final se exporta en formato **.keras** (formato nativo de Keras), permitiendo su posterior reutilización para inferencias sin necesidad de

reentrenamiento. El archivo se almacena en el directorio de trabajo designado, con una nomenclatura que incorpora el identificador único del experimento.

- **Documentación reproducible**:

  Se actualiza automáticamente el cuaderno de Colab con el ID experimental correspondiente, estableciendo así una conexión que no se repita entre el código ejecutado, los resultados obtenidos y el modelo serializado.

Figura 12

Código para guardar el modelo para futuros usos

```
# prompt: salvar el modelo en el directorio de trabajo

model.save(f"{directorio_de_trabajo}/experimentos/{ID_Exp}_model.keras")
```

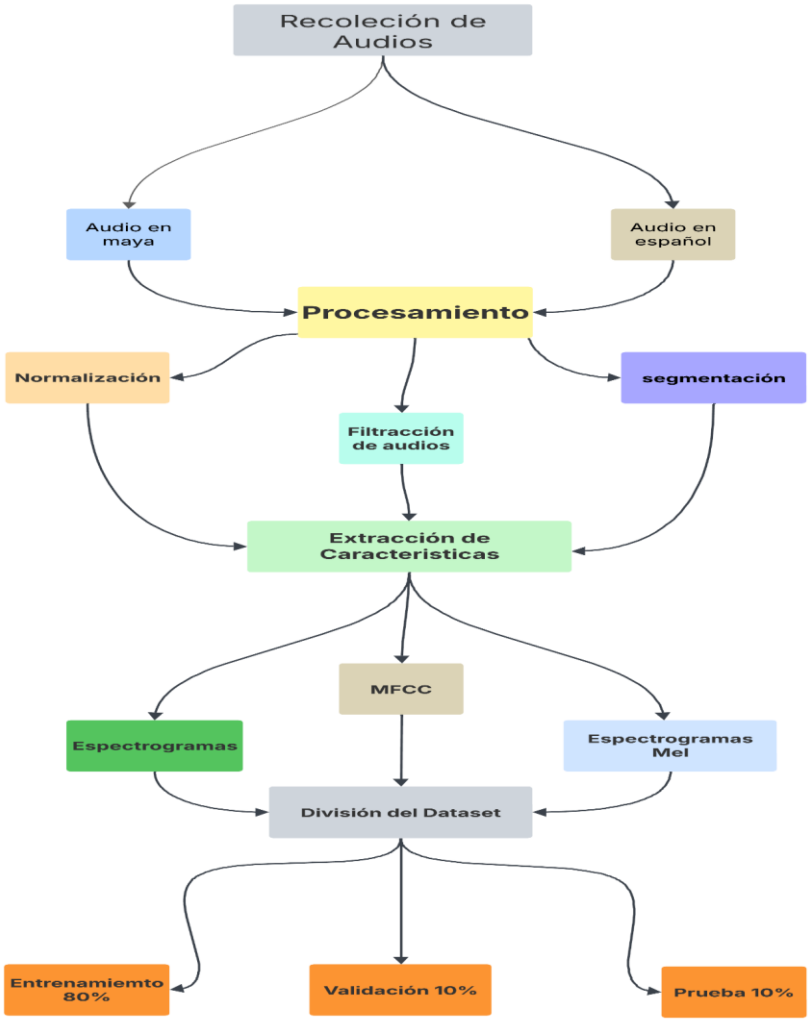
Guarda el notebook manualmente anteponiendi {ID_Exp}_

3.7 DIAGRAMAS DEL PROCESO

Este diagrama representa la serie de pasos que se llevaron a cabo desde la recolección de los audios, procesamiento, extracción y división del dataset:

Figura 13

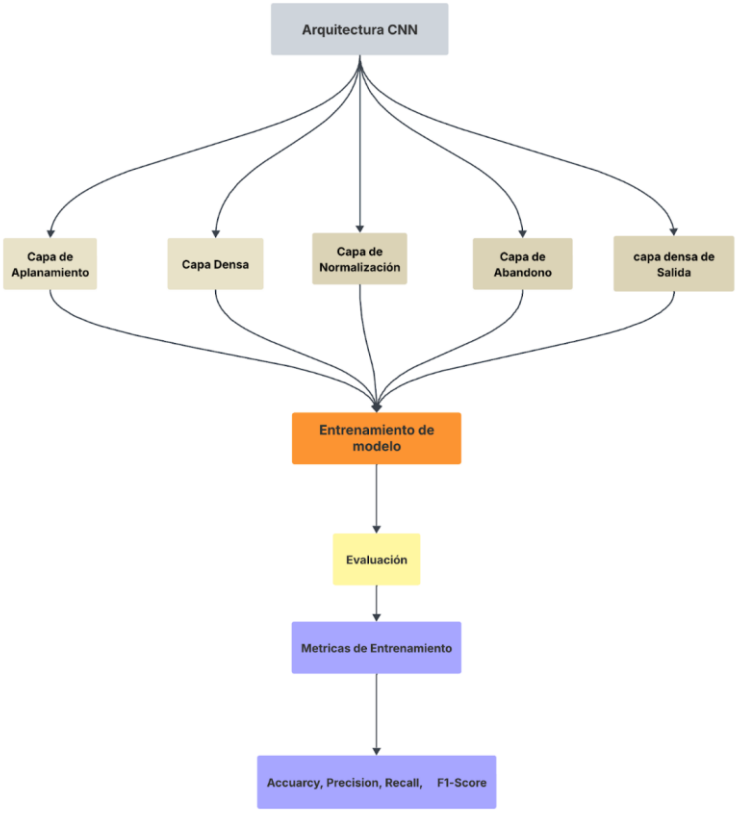
Diagrama del proceso de corpus e inicio de experimentos



El siguiente diagrama representa la segunda fase del proceso, desde la arquitectura CNN hasta las fases de entrenamiento.

Figura 14

Diagrama que representa la segunda fase de los experimentos



UNIDAD IV. ANÁLISIS E INTERPRETACIÓN DE RESULTADOS

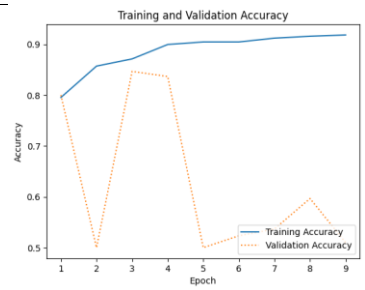
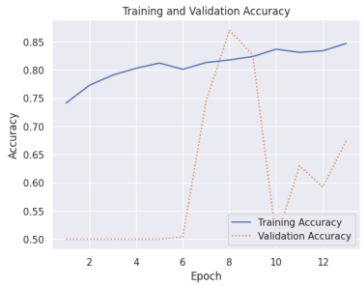
4.1 ENTRENAMIENTO INICIAL

Para probar qué tan bien funcionan tres tipos diferentes de arquitecturas ligeras (MobileNetV2, MobileNetV3 y EfficientNetB0), se hizo un primer entrenamiento usando una base de datos con 3,850 audios en maya y español que se convirtieron en imágenes llamadas espectrogramas a color. Sin embargo, debido a las limitaciones de memoria y capacidad de procesamiento del entorno de entrenamiento alojado en Google Colab y el equipo disponible, solo se pudieron usar 1,400 espectrogramas por cada lengua.

Los datos se organizaron de la siguiente manera: 80% se usó para que los modelos aprendieran, 10% se utilizó para revisar su progreso durante el entrenamiento, y el 10% restante se guardó para hacer la prueba final. Para que la comparación entre los tres modelos fuera justa, se usaron los mismos ajustes para todos: se procesaron grupos de 20 imágenes a la vez, se entrenaron durante 30 rondas completas, y se configuró la velocidad de aprendizaje en 0.0001. En esta fase se observó un patrón consistente en los tres modelos:

Tabla 3

Graficas de las curvas de aprendizaje de los experimentos 1, 2 y 3

Curva de aprendizaje	Parámetros
	Experimento 1 MobileNetV2 – 1400 espectrogramas, split 80/10/10, batch=20, epochs=30, LR=1e-4, sin Data Augmentation. Accuracy=0.83, Recall=0.68, Precision=0.96, F1=0.80
	Experimento 2 MobileNetV3 – 1400 espectrogramas, split 80/10/10, batch=20, epochs=30, LR=1e-4, sin Data Augmentation. Accuracy=0.77, Recall=0.80, Precision=0.76, F1=0.78
	Experimento 3 EfficientNetB0 – 1400 espectrogramas, split 80/10/10, batch=20, epochs=30, LR=1e-4, sin Data Augmentation. Accuracy=0.60, Recall=0.22, Precision=0.91, F1=0.36

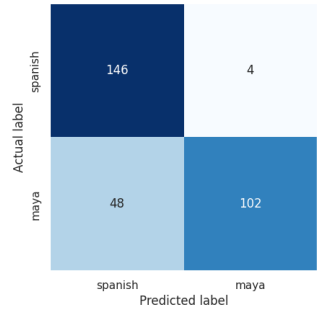
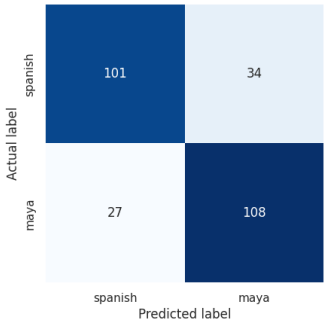
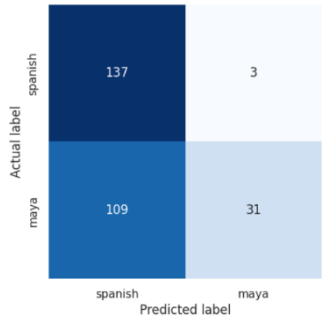
Durante el entrenamiento, los modelos mostraron que estaban aprendiendo a identificar correctamente las características de los espectrogramas (*Training Accuracy).* Sin embargo, cuando se probaron estos modelos con audios nuevos que no habían escuchado antes, los resultados fueron inestables y a veces bajaron de forma repentina (*Validation Accuracy*).

Esta diferencia entre lo bien que funcionaban durante el aprendizaje y lo mal que funcionaban con audios nuevos indica un problema: los modelos memorizan muy bien los espectrogramas que ya conocen, pero tienen dificultades para reconocer audios que nunca habían escuchado antes. Es como cuando un estudiante memoriza las respuestas de un examen específico, pero no puede resolver problemas similares en un examen diferente.

Los resultados mostraron que los modelos son mucho mejores reconociendo el español que el maya. Por ejemplo, dos de los modelos probados (MobileNetV2 y EfficientNetB0) identificaron correctamente 146 y 137 audios en español respectivamente, pero cometieron muchos más errores cuando intentaban reconocer audios en maya. Esta diferencia se debe principalmente a dos factores: primero, se tenían pocos ejemplos de espectrograma en maya para enseñarle al modelo debido a la capacidad de memoria de la máquina, y segundo, los sonidos del maya son más variados que los del español, lo que hace que sea más difícil para el programa aprenderlos.

Tabla 4

Graficas de las matrices de confusión de los experimentos 1, 2 y 3

Matriz de confusión	Interpretación de resultados
	MobileNetV2 El modelo mostró buen desempeño en la clasificación del español, con 146 aciertos, pero presentó dificultades con el Maya donde solo acertó 102 espectrogramas y fallo con 48 evidenciando un sesgo hacia el español.
	MobileNetV3 Este modelo mantuvo un desempeño más equilibrado entre ambas clases, aunque con menor exactitud general que MobileNetV2. Reconoció mejor el maya con 108 aciertos en comparación con el español que solo obtuvo 101 de 130.
	EfficentNetB0 El modelo tuvo un rendimiento muy alto en español con 137 aciertos, pero muy bajo en maya con solo 31 aciertos. Se puede ver un fuerte desequilibrio, ya menos de la mitad del idioma maya fue acertado.

Los resultados de las matrices de confusión mostraron que los modelos lograron superar la mitad de los aciertos en ambos idiomas. Sin embargo, las gráficas revelaron un desbalance considerable entre las clases, evidenciando una falta significativa de datos, especialmente en los espectrogramas de Maya. Esta limitación se debió principalmente a las restricciones del entorno de trabajo: el equipo alcanzó su límite de memoria RAM, las métricas no eran favorables para la cantidad de datos que se podían procesar, y la GPU alojada en servidores externos de Google Colab que solo estaba disponible por tiempo limitado.

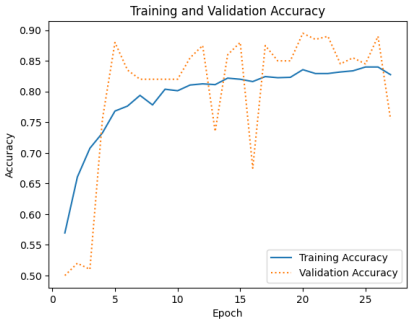
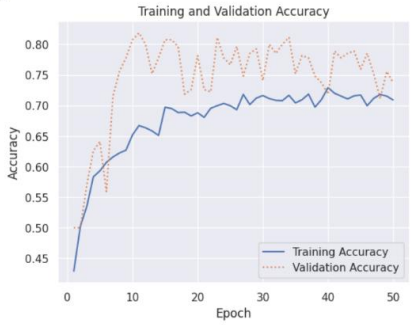
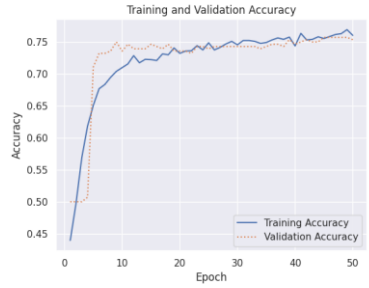
4.2 ENTRENAMIENTO CON DATA AUGMENTATION

Ante estas limitaciones técnicas, fue necesario buscar alternativas para mejorar el rendimiento de los modelos. Se decidió implementar la estrategia de aumento de datos (*data augmentation*), una técnica que permite generar variaciones de los datos existentes para ampliar artificialmente el conjunto de entrenamiento. Esta estrategia busca compensar la escasez de datos originales y mejorar la capacidad de generalización de los modelos.

Bajo las mismas condiciones de división de datos y con ajustes mínimos por arquitectura, los resultados fueron:

Tabla 5

Graficas de las curvas de aprendizaje de los experimentos 4, 5 y 6

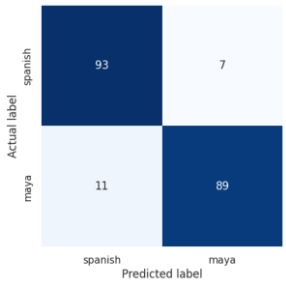
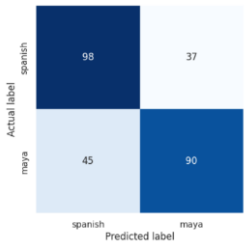
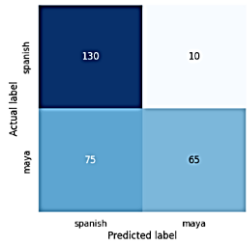
Curva de aprendizaje	Parámetros
	Experimento 4 MobileNetV2 – 1400 espectrogramas, split 80/10/10, batch=20, epochs=30, LR=1e-4, con Data Augmentation. Accuracy=0.91, Recall=0.89, Precision=0.93, F1=0.91
	Experimento 5 MobileNetV3 – 1400 espectrogramas, split 80/10/10, batch=20, epochs=30, LR=5e-5, con Data Augmentation. Accuracy=0.71, Recall=0.67, Precision=0.73, F1=0.70
	Experimento 6 EfficientNetB0 – 1400 espectrogramas, split 80/10/10, batch=22, epochs=50, LR=1e-6, con Data Augmentation. Accuracy=0.70, Recall=0.46, Precision=0.87, F1=0.60

Los resultados mostraron una mejora considerable respecto a los primeros experimentos. En general, los modelos presentaron un comportamiento más estable durante el entrenamiento y obtuvieron métricas más equilibradas entre ambas lenguas. El mejor desempeño lo alcanzó MobileNetV2 con 91% de exactitud y valores altos en precisión, recuperación y F1, indicando un reconocimiento consistente de ambas clases con pocos errores. MobileNetV3 y EfficientNetB0 mostraron rendimientos más moderados, con exactitudes del 70% y 69% respectivamente. Un aspecto notable fue que MobileNetV3 logró mantener un comportamiento balanceado sin sesgo hacia alguna lengua, mientras que EfficientNetB0 presentó patrones dispares: alta precisión en sus predicciones correctas, pero dificultades para identificar todos los ejemplos, especialmente en la clase maya.

Además de estos números generales, se crearon tablas llamadas matrices de confusión para cada modelo. Estas tablas muestran no solo cuántos audios clasificaron correctamente, sino también los errores que cometió cada modelo: cuántos audios en maya confundió como español y viceversa.

Tabla 6

Graficas de las matrices de confusión de los experimentos 4, 5 y 6

Matriz de confusión	Interpretación de resultados
	MobileNetV2 El modelo mostró excelente desempeño balanceado, acertando 93 audios en español con solo 7 errores, y 89 audios en Maya con 11 errores. Presenta un comportamiento equilibrado entre ambas clases.
	MobileNetV3 El modelo logró un desempeño moderado pero balanceado, acertando 98 audios en español con 37 errores, y 90 audios en Maya con 41 errores. Muestra consistencia similar entre ambas lenguas.
	EfficentNetB0 El modelo tuvo excelente desempeño en español con 130 aciertos y solo 10 errores, pero falló considerablemente en Maya donde solo acertó 65 casos y confundió 75 como español. Evidenciando un mejor rendimiento hacia el español.

En conjunto, los resultados demuestran que el aumento artificial de dato representó una mejora significativa en el desempeño de los modelos de reconocimiento de idiomas. Mientras que en los experimentos iniciales se observaron problemas de sobreajuste y sesgo pronunciado hacia el español, la segunda fase mostró que es posible obtener modelos más equilibrados y confiables cuando se cuenta con suficiente diversidad en los datos de entrenamiento.

UNIDAD V. CONCLUSIONES

5.1 RESULTADOS MÁS RELEVANTES

Los experimentos realizados con los modelos MobileNetV2, MobileNetV3 y EfficientNetB0 permitieron identificar varios hallazgos importantes. En primer lugar, se pudo observar que modelos ligeros como estos, pueden ser entrenados con una cantidad de espectrogramas reducida, pero mostrando resultados que no son los ideales. Durante la primera fase de experimentos, los tres modelos mostraron un alto nivel de aciertos, pero no podían reconocer nuevos ejemplos, lo que mostro un problema de sobreajuste y un claro sesgo hacia el español.

En la segunda fase, y después de haber buscado nuevas técnicas para poder arreglar el sobreajuste mostrado en los primeros experimentos, se decidió aumentar el número de espectrogramas de una manera artificial usando la estrategia conocida como *data augmentation*. Con esto los resultados pasaron de “solo memorizar” a “aprender” de manera considerable, donde el modelo MobileNetV2 tuvo los mejores resultados: Accuracy: 0.91, Recall: 0.89, Precision: 0.93, F1 Score: 0.915, eliminando el sesgo marcado hacia el español que observamos en los primeros experimentos. Con los otros modelos los resultados, aunque no tan notables, si mostraron mejoras, evidenciando la optimización del entrenamiento.

5.2 CONCLUSIONES GENERALES

A la luz de los resultados obtenidos, esta investigación responde a la pregunta principal de cómo el entrenamiento y evaluación de modelos ligeros de CNN puede contribuir al desarrollo de herramientas viables para comunidades Maya hablantes. En concreto, el trabajo permitió identificar que la arquitectura MobileNetV2, optimizada con técnicas de aumento artificial de datos, no solo alcanza un alto rendimiento (91% de precisión), sino que lo hace de manera equilibrada entre el Español y la lengua Maya. Esto demuestra que es posible desarrollar prototipos tecnológicos ligeros y accesibles, incluso con recursos computacionales limitados como los que se encuentran en entornos comunitarios.

De manera general, el trabajo mostró que es posible entrenar modelos de aprendizaje ligeros para el aprendizaje en el reconocimiento de espectrogramas de audios en lenguas originarias como lo es el Maya, así como la posibilidad de que más personas de comunidades originarias puedan hacerlo, ya que durante el trabajo pudimos experimentar con computadoras no especializadas para este tipo de trabajo, demostrando que buscar diferentes opciones como los distintos modelos, o experimentar con técnicas adecuadas como *data augmentation* es posible. El entrenamiento inicial nos dejó ver que los corpus pequeños limitan la capacidad de generalización de los modelos, dando sesgos hacia idiomas como el español, y no reconociendo el maya, ya sea por la cantidad de espectrogramas, o que el idioma presenta diferentes formas de expresión.

Cuando aplicamos la técnica de *data augmetation* resulto ser una decisión favorable, porque nos permitió compensar la escasez de datos que nos limitaba, haciendo posible que los experimentos sean más equilibrados entre los modelos y las lenguas del maya y español, esto nos

da la posibilidad de futuros escenarios o futuros trabajos de este tipo donde no es posible acceder a grandes corpus, ya que esta técnica donde agregaba una variación artificial de los datos fue fundamental para mejorar el desempeño de los modelos.

Algo importante es que las nuevas tecnologías cada vez son más accesibles en lugares como José María Morelos. Esto significa que, con los conocimientos adecuados y aprovechando lo que se tiene a la mano, estas herramientas pueden servir no solo para experimentos académicos, sino también para la preservación y reconocimiento de la lengua Maya y de otras lenguas indígenas.

5.3 LIMITACIONES

Este trabajo lo realizamos enfrentando varias limitaciones. Para empezar, los programas de computación, en muchas universidades de México y Latinoamérica, aún no integran estos temas avanzados de inteligencia artificial, y ese es el caso de nuestra comunidad. Sabíamos más o menos de qué se trataba, comenzaba a sonar el tema de entrenamientos de inteligencias artificiales, pero no teníamos idea de cómo hacerlo ni de qué pasos seguir. Así que fuimos aprendiendo poco a poco. Primero tuvimos que averiguar qué herramientas necesitaríamos para comenzar. Entre estas herramientas estuvo Praat, tuvimos que investigar qué es Praat, cómo usarlo, cómo obtener espectrogramas, incluso tomamos un curso rápido con un estudiante de la UADY[9]. De ahí comenzamos a trabajar con un corpus paralelo en maya y en español que nos habían proporcionado, pero no eran suficientes datos, así que tuvimos que incorpora otro corpus de un trabajo previo, para poder seguir con los experimentos.

[9] Jean Carlos Buenfil trabajó recientemente en el tema entrenando otros modelos.

Entre los siguientes pasos se encontraba organizar los audios, eso también fue un reto. Los separamos en carpetas en la memoria local. Las carpetas estaban divididas, una con maya y otra con español. Este paso consistía en escuchar los audios y de manera manual enviarlos a sus respectivas carpetas nombradas. Como uno de nosotros domina el maya, pudo avanzar más rápido, apoyándose con un script en Python para separar más rápido. El script reproducía el audio de manera automática, y con los números 1 y 2 los enviaba a sus respectivas carpetas, siendo 1 para el Maya y 2 para el español. Por rapidez, el trabajo lo dividimos para terminar este paso más rápido, pero para el otro estudiante fue complicado, ya que, aunque es de familia maya originaria, él no domina la lengua. Le tocó pedir ayuda a sus familiares que sí hablan maya para poder avanzar, y aunque le costó, al final logró emparejar los audios en la las carpetas.

Otro obstáculo fue la parte técnica. Nos presentaron Google Colab como espacio de trabajo, pero nunca lo habíamos usado. Al principio fue complicado, y más cuando vimos que de los 3,850 audios solo pudimos procesar 1,400, porque nuestras computadoras no eran lo suficientemente potentes para generar todos los espectrogramas. Además, Colab nos prestaba una GPU gratuita, pero con tiempo limitado, así que muchas veces justo cuando queríamos probar más métricas o experimentar, se nos cerraba la sesión. Por eso tuvimos que optar por usar modelos ligeros y más sencillos, aunque eso también limitó la posibilidad de entrenar arquitecturas más grandes.

También notamos que el maya tiene más variabilidad en su sonido que el español, lo que hizo más difícil que el modelo lo reconociera bien con tan pocos ejemplos. Todo esto nos mostró que trabajar con IA en una comunidad como la nuestra no es imposible, pero sí requiere de

mucha paciencia, de aprender sobre la marcha y de buscar soluciones creativas a las limitaciones de recursos.

5.4 RECOMENDACIONES FINALES

Con base en lo que vivimos en este trabajo, consideramos que hay varias cosas que se pueden mejorar o tomar en cuenta para investigaciones futuras. Lo primero es ampliar el corpus de audios y mantener un balance entre el maya y el español, ya que observamos que cuando hay más de un idioma los modelos tienden a inclinarse hacia alguno de ellos. También sería muy útil contar con computadoras o servidores más potentes, porque nuestras máquinas fueron una gran limitación, y con mejores equipos sería posible entrenar modelos más grandes y con mayor cantidad de datos.

De igual forma sería importante extender este tipo de trabajos a otras lenguas originarias, ya que muchas están en riesgo de desaparecer y estas tecnologías podrían ser una herramienta para preservarlas. Para que eso sea posible, creemos que hace falta ofrecer talleres y materiales de formación accesibles, dirigidos a jóvenes y personas de la comunidad, de modo que no se sientan limitados por lo técnico. También comenzar a actualizar el plan de estudio de la universidad, para que las nuevas generaciones puedan desde el principio adentrarse a esta línea de trabajo que va en aumento.

Finalmente, pensamos que es importante fortalecer las colaboraciones entre instituciones y universidades, pero lo más importante, colaboración con las comunidades hablantes, ya que son una parte fundamental en este tipo de trabajo que buscar rescatar la lengua, dar a conocer el trabajo para que sepan donde participan y así sumar aprobación de las mismas comunidades. Y algo que consideramos clave es que los futuros trabajos no se queden únicamente en

experimentos académicos, sino que puedan transformarse en proyectos con impacto social, como aplicaciones educativas, juegos o herramientas que sirvan en las escuelas y espacios comunitarios.

UNIDAD VI. BIBLIOGRAFÍA Y ANEXOS

6.1. REFERENCIAS

Alsentzer, E., Murphy, J. R., Boag, W., Weng, W. H., Jin, D., Naumann, T., & McDermott, M. (2019). *Publicly available clinical BERT embeddings*. arXiv preprint arXiv:1904.03323.

Arámbula Cosío, F., Chávez Núñez, L., Hernández Morales, J., & Téllez Ruíz, L. (2021). *Procesamiento del lenguaje natural y modelos generativos: GPT-3*. Revista Digital Universitaria, 22(6), 1–14.

Arana, C. (2021). *Redes neuronales recurrentes: Análisis de los modelos especializados en datos secuenciales* (No. 797). Serie Documentos de Trabajo.

Badillo, F. L., Hernández, C. A. R., Narváez, B. M., & Trillos, Y. E. A. (2021). *Redes neuronales convolucionales: un modelo de Deep Learning en imágenes diagnósticas.* Revista Colombiana de Radiología, 32(3), 5591–5599.

Beltrán, N. C. B., & Mojica, E. C. R. (2020). *Procesamiento del lenguaje natural (PLN)-GPT-3: Aplicación en la Ingeniería de Software*. Tecnología Investigación y Academia, 8(1), 18–37.

Bricker, V. R. (1999). *The Mayan Languages*. In *The Cambridge History of the Native Peoples of the Americas* (Vol. 2, pp. 386–427). Cambridge University Press.

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., et al. (2020). *Language models are few-shot learners*. arXiv:2005.14165.

Carreón Díaz de León, C. L. (2023). *Desarrollo de una red neuronal convolucional para la identificación paramétrica de un robot* [Tesis de licenciatura, Universidad Autónoma del Estado de México].

Castillo Tzec, F.: U áanalte'il u tsikbalil ts'aak (Manual de frases médicas). Inde maya, Mérida, México (2013), edición bilingüe maya-Español

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). *BERT: Pre-training of deep bidirectional transformers for language understanding*. arXiv:1810.04805.

England, N. C. (1994). *Autonomía de los pueblos Mayas y revitalización de sus lenguas*. México: CIESAS.

Evert, S. (2015). *The Statistics of Word Cooccurrences: Word Pairs and Collocations*. In A. Lüdeling & M. Kytö (Eds.), *Corpus Linguistics: An International Handbook* (pp. 1212–1248). Berlin: De Gruyter.

González, A., & Centenera, R. (2020). *Transformers y modelos de lenguaje: una nueva era en el PLN*. Universidad Autónoma de Madrid.

Graves, A. (2014). *Neural Networks: Tricks of the Trade* (2nd ed.). Springer.

Guanoluisa, J. M., Chicaiza, R. P. M., & Avalos, C. J. B. (2021). *Agente conversacional para consultas sobre servicio médico en una clínica privada*. 3C Tecnología: Glosas de innovación aplicadas a la pyme, 10(2), 47–71.

INALI. (2009). *Catálogo de las lenguas indígenas nacionales: Variantes lingüísticas de México con sus autodenominaciones y referencias geoestadísticas*. Instituto Nacional de Lenguas Indígenas.

INEGI. (2020). *Censo de Población y Vivienda 2020. Lenguas indígenas nacionales*. Instituto Nacional de Estadística y Geografía.

Jurafsky, D., & Martin, J. H. (2025). *Procesamiento del habla y el lenguaje* (Borrador, 12 de enero de 2025, Cap. 3). Pearson Education.

Labadie, J. L. (2001). *El lenguaje natural*. Iztapalapa: Revista de Ciencias Sociales y Humanidades, (50), 257–270.

LeCun, Y., Bengio, Y., & Hinton, G. (2015). *Deep learning*. Nature, 521(7553), 436–444. https://doi.org/10.1038/nature14539

Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., & Kang, J. (2020). *BioBERT: A pre-trained biomedical language representation model for biomedical text mining*. Bioinformatics, 36(4), 1234–1240.

Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., et al. (2019). *BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension.* arXiv:1910.13461.

Lou, A., Pérez-Ortiz, J. A., Sánchez-Martínez, F., & Sánchez-Cartagena, V. (2024). *Curated datasets and neural models for machine translation of informal registers between Mayan and Spanish vernaculars*. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language*

Technologies (Vol. 1: Long Papers, pp. 2838–2850). Association for Computational Linguistics.

Martín, P., Briceño, F.: Manual de comunicación para médicos. Universidad Autónoma de Yucatán, Mérida, México (2013)

Maxwell, M., & Hughes, B. (2006). *Frontiers in linguistic annotation for less commonly studied languages*. Proceedings of the Workshop on Frontiers in Linguistically Annotated Corpora, 29–37.

McEnery, T., & Hardie, A. (2012). *Corpus Linguistics: Method, Theory and Practice*. Cambridge: Cambridge University Press.

Merino de la Fuente, J. M., & Muñoz-Repiso, L. (2013). La percepción acústica: Física de la audición. Revista de Ciencias, (2), 19-26.

Molina Marco, A. (2004). *Desambiguación en procesamiento del lenguaje natural mediante técnicas de aprendizaje automático* [Tesis doctoral, Universidad Politécnica de Valencia].

Olabe, X. B. (1998). *Redes neuronales artificiales y sus aplicaciones* (Vol. 5). Publicaciones de la Escuela de Ingenieros.

OpenAI, Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). *Improving language understanding by generative pre-training*. OpenAI.

Palma, L., Herrera, P., Ceballos, J., & Martínez, A. (2024). *Inteligencia artificial y ética médica: Retos en el uso de tecnologías automatizadas en salud*. Revista de Bioética y Derecho, 20(1), 55–68.

Patiño-Londoño, S. Y., Mignone, J., Castro-Arroyave, D. M., Valencia, N. G., & Rojas Arbeláez, C. A. (2016). *Guías bilingües: una estrategia para disminuir las barreras culturales en el acceso y la atención en salud de las comunidades wayuu de Maicao, Colombia*. Salud Colectiva, 12, 415–428.

Pérez Guerrero, J. (2020). *Redes recurrentes* [Manuscrito].

Piech, C. (2018, November 26). *Naive Bayes* [Lecture 24, CS109]. Stanford University. https://web.stanford.edu/class/archive/cs/cs109/cs109.1196/lectureNotes/24%20-%20NaiveBayes.pdf

Pugh, R., Castañeda, Q., & Tyers, F. (2023). *Developing finite-state language technology for Maya*. Department of Linguistics, Indiana University; Center for Latin-American and Caribbean Studies; Open School of Ethnography and Anthropology (OSEA-CITE).

Quevedo-Marcos, N. (2020). *PLN en medicina: problemas semánticos en la extracción de entidades clínicas*. Lingüística y Sociedad, 12(2), 34–47.

Raffel, C., Shazeer, N., Roberts, A., Lee, K., et al. (2019). *Exploring the limits of transfer learning with a unified text-to-text transformer*. arXiv:1910.10683.

Ramos Ramírez, J. A., & Islas Flores, M. J. (2019). *Lenguas indígenas y derechos culturales en México: entre la normatividad y la práctica*. Revista Latinoamericana de Derechos Humanos, 30(2), 149–168.

Rangel, J., & Kobayashi, N. (2024). *Advancing NMT for Indigenous Languages: A Case Study on Yucatec Mayan and Chol*. In *Proceedings of the 4th Workshop on Natural Language*

Processing for Indigenous Languages of the Americas (AmericasNLP 2024) (pp. 138–142). Association for Computational Linguistics.

Reinoso González, J., & Zhirzhan Cabrera, M. (2022). *Ambigüedad léxica en terminología médica: desafíos para el procesamiento automático del lenguaje*. Revista Cubana de Informática Médica, 24(1), 15–27.

Richardson, I., & Tyers, F. M. (2021). *A morphological analyser for K'iche' / Un analizador morfológico para el idioma k'iche'*. Department of Linguistics, Indiana University; National Research University Higher School of Economics.

Riofrío, C. H. E., Guamán, K. V., & García, R. Y. (2022). *Clasificación y etiquetado de tweets de Ecuador para determinar qué tema tratan, utilizando un modelo Transformer*. Polo del Conocimiento: Revista científico-profesional, 7(3), 34.

Salas, R. (2004). *Redes neuronales artificiales*. Universidad de Valparaíso, Departamento de Computación, 1(1), 1–7.

Tyers, F., & Howell, N. (2021). *A survey of part-of-speech tagging approaches applied to K'iche'*. In *Proceedings of the First Workshop on Natural Language Processing for Indigenous Languages of the Americas* (pp. 44–52). Association for Computational Linguistics.

UNESCO. (2023). *Inteligencia artificial centrada en los pueblos indígenas: perspectivas desde América Latina y el Caribe*. Oficina de la UNESCO en México y Montevideo. https://www.unesco.org/en/articles/new-report-and-guidelines-indigenous-data-sovereignty-artificial-intelligence-developments

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). *Attention is all you need*. Advances in Neural Information Processing Systems (NeurIPS), 30.

Zárate, I. R., Bolaños, M. H., & Romero, P. P. (2020) . *Redes neuronales recurrentes para el procesamiento de secuencias codificado en Python*.